



MATERIA

Introducción a la Ciencia de Datos


ICD · PRIMER CUATRIMESTRE

CÓDIGOS QR

Estimado Alumno:

Esta materia puede contener **Códigos QR** para agilizar el acceso a los contenidos audiovisuales que el docente ha desarrollado especialmente para Usted.

Para poder visualizar los videos utilice el lector de código QR que trae por defecto su teléfono o dispositivo móvil. En caso de no disponer de uno, puede descargarlo desde *Google Play* si su sistema operativo corresponde a Android o desde la *App Store* si utiliza IOS.



Una vez instalado el software en su dispositivo móvil:

- 1) Abra la aplicación
- 2) Apunte con la cámara de su dispositivo hacia los códigos QR que encuentre en el interior de su materia.



De esta manera estará visualizando los videos que el docente ha desarrollado y/o seleccionado especialmente para usted.

Índice

Bienvenida	4
Propósito	4
Competencias	6
Objetivos	7
Contenidos mínimos	8
Contenidos	8
Bibliografía	9
Planificación	9
Metodología	10
Evaluación	11
Módulos	
› Módulo 1	12
› Módulo 2	33
› Módulo 3	50
› Módulo 4	61
› Módulo 5	70
› Módulo 6	79

Importante

Lecturas básicas y complementarias disponibles desde plataforma.

Importante

Lecturas básicas y complementarias disponibles desde plataforma.

Impresión total del documento 87 páginas

Bienvenida

Bienvenidos a la materia:

"Introducción a la ciencia de datos"

Propósito



Fuente: Freepik

¡Bienvenido/a a la asignatura Introducción a la Ciencia de Datos!

Esta materia ofrece una introducción general del campo para quienes dan sus primeros pasos en la carrera: veremos qué es la ciencia de datos, qué problemas aborda, qué roles y competencias intervienen y cómo se organiza el trabajo de manera básica, sin entrar aún en profundizaciones técnicas. La idea es que, al avanzar en los distintos módulos, entiendan el mapa completo antes de recorrer cada camino en detalle en materias posteriores.

A lo largo del cursado, vas a reconocer datos y fuentes habituales, realizar tus primeras consultas simples en SQL y aplicar un análisis exploratorio (EDA) elemental para describir y visualizar información. También se acercará a los modelos predictivos más básicos y a la segmentación como ejemplo de métodos no supervisados, siempre con foco en criterio práctico, lenguaje claro y reproducibilidad inicial del trabajo. Estos temas se presentan a nivel introductorio para que pueda familiarizarte con el ciclo de vida típico (desde la pregunta hasta comunicar hallazgos) y con nociones clave de calidad de datos, sesgos y ética.

A lo largo del cursado se abordarán de manera progresiva los principales conceptos que estructuran el campo de la ciencia de datos. En el Módulo 1 se comenzará trabajando sobre la figura del científico o científica de datos, analizando el concepto, su alcance y las competencias técnicas y transversales que caracterizan este perfil profesional. También

se presentarán los distintos perfiles y áreas de actuación dentro del ecosistema de datos, junto con un panorama general de los lenguajes más utilizados en este campo como SQL, R y Python— y de las herramientas habituales del entorno de trabajo. En el Módulo 2 se introducirá el estudio de los datos, sus tipos y características básicas, diferenciando entre datos estructurados y semiestructurados a nivel introductorio. Asimismo, se examinarán fuentes de datos frecuentes (como archivos y bases de datos) y se trabajará sobre criterios fundamentales de calidad de los datos, tales como completitud, consistencia y validez, analizando cómo estos aspectos influyen directamente en la confiabilidad de los análisis posteriores.

En los módulos siguientes se recorrerán las principales etapas del trabajo en ciencia de datos. En el Módulo 3 se abordará el proceso de extracción, transformación y carga (ETL), presentando de manera introductoria cómo se obtienen los datos desde distintas fuentes, cómo se realiza su limpieza y preparación básica y cómo se integran en un conjunto de datos apto para el análisis, incorporando además nociones iniciales de trazabilidad y registro del proceso. En el Módulo 4 se desarrollará el análisis exploratorio de datos (EDA), utilizando descriptores simples y visualizaciones iniciales para comprender la estructura del conjunto de datos, identificar valores faltantes o atípicos y formular primeras preguntas o hipótesis de trabajo. Posteriormente, en el Módulo 5, se presentarán las ideas generales de modelización desde una perspectiva conceptual, introduciendo los enfoques supervisados y los propósitos de la predicción y la clasificación mediante ejemplos básicos, junto con una primera aproximación a la evaluación de resultados mediante métricas simples. Finalmente, el Módulo 6 se centrará en la segmentación o agrupamiento como ejemplo de métodos no supervisados, analizando su objetivo y aplicaciones iniciales, así como el proceso de extracción de conocimiento a partir de los resultados obtenidos. En esta última etapa también se abordará la comunicación de hallazgos, los límites del análisis y la importancia de considerar criterios de ética, responsabilidad y reproducibilidad en el trabajo con datos.

Al finalizar, contará con una visión integrada de la disciplina sus conceptos, herramientas iniciales y buenas prácticas que le servirá de base para profundizar en las asignaturas siguientes del plan de estudios.

Competencias

Relación de la asignatura con las competencias de egreso

En la tabla siguiente se establece la relación de la asignatura con las competencias de egreso: Específicas, Genéricas Tecnológicas, Sociales, Políticas y Actitudinales de la carrera. Se incluyen las competencias de egreso a las que tributa su nivel de aporte (ninguno, bajo, medio y alto).

Competencias Genéricas Tecnológicas (CG)	Nivel
CG1. Identificación, formulación y resolución de problemas de informática.	media
CG2. Concepción, diseño y desarrollo de proyectos de informática.	media
CG3. Gestión, planificación, ejecución y control de proyectos de informática.	media
CG4. Utilización de técnicas y herramientas de aplicación en la informática.	media
CG5. Generación de desarrollos tecnológicos y/o innovaciones tecnológicas.	baja

Competencias Sociales, Políticas y Actitudinales (CSPA)	Nivel
CSPA6. Desempeño en equipos de trabajo.	alta
CSPA7. Comunicación efectiva.	media
CSPA8. Acción ética y responsable.	alta
CSPA9. Evaluación y actuación en relación con el impacto social de su actividad en el contexto global y local.	media
CSPA10. Aprendizaje continuo.	media
CSPA11. Acción emprendedora	media

Competencias Específicas (CE)	Nivel
CE 1.1 SI Especificación, proyección, desarrollo de sistemas de información y análisis de datos	media
CE 1.2 SCD Especificación, proyección y desarrollo de sistemas de comunicación y análisis de datos	media
CE 1.3 S Especificación, proyección y desarrollo de software	baja
CE 2.1 SI Proyección y dirección de lo referido a seguridad informática.	media
CE 3.1 M Establecimiento de métricas y normas de calidad de software.	media

CE 4.1 C Certificación del funcionamiento, condición de uso o estado de sistemas de información, sistemas de comunicación de datos, software, seguridad informática y calidad de software.	baja
CE5.1 D Dirección y control de la implementación, operación y mantenimiento de sistemas de información, sistemas de comunicación de datos, software, seguridad informática y calidad de software.	baja

Resultados de Aprendizaje (RA)

Resultado	Descripción
RA1	Reconocer los conceptos fundamentales de la ciencia de datos, sus áreas de aplicación, roles profesionales, herramientas iniciales y etapas del ciclo de trabajo, para construir una visión general e integrada del campo.
RA2	Identificar y caracterizar tipos de datos, fuentes habituales y criterios básicos de calidad, a fin de valorar su influencia en la confiabilidad de los procesos de análisis y toma de decisiones.
RA3	Aplicar procedimientos introductorios de consulta, preparación y exploración de datos, mediante consultas simples en SQL, tareas básicas de ETL y análisis exploratorio elemental, para describir, visualizar e interpretar información de manera inicial.
RA4	Distinguir y comunicar de forma introductoria los propósitos de los enfoques supervisados y no supervisados, así como los hallazgos básicos obtenidos en un análisis, considerando criterios iniciales de ética, sesgo, responsabilidad y reproducibilidad.

Objetivos

- › Comprender el campo de la ciencia de datos a través de un panorama inicial, integrado y práctico de sus conceptos, roles, etapas y herramientas básicas, con el propósito de desarrollar nociones operativas que se profundizarán en materias posteriores.
- › Reconocer el campo y sus roles para entender qué es la ciencia de datos, qué problemas aborda y cuáles son sus etapas fundamentales.
- › Trabajar con datos básicos con el objetivo de identificar tipos y fuentes habituales, aplicar criterios elementales de calidad de datos y ejecutar consultas SQL simples para obtener/combinar datasets pequeños.
- › Aplicar EDA y visualización inicial para poder describir datos con medidas simples y gráficos introductorios (barras, histogramas, dispersión) para formular primeras hipótesis.

- › Comprender modelos y segmentación a nivel inicial a fin de explicar el propósito de regresión y clasificación, interpretar métricas básicas (MAE/MSE, accuracy, matriz de confusión) e identificar el agrupamiento (k-means) como ejemplo de no supervisado y cuándo usarlo.
- › Desarrollar la capacidad de comunicarse con claridad y responsabilidad, elaborando una síntesis breve de hallazgos (texto + gráficos), registrando el trabajo en un notebook reproducible (semillas, versiones), y reconociendo sesgos y consideraciones éticas, con el propósito de promover hábitos de aprendizaje continuo y colaboración.

Contenidos mínimos

Científico de datos: competencias. Lenguajes en ciencia de datos: SQL, R y Python, principales programas, perfiles profesionales y áreas de actuación. Datos: tipos y características, fuentes de datos, calidad de datos. Etapas en ciencia de datos: extracción, transformación y carga, análisis exploratorio, segmentación, agrupamiento, modelización, predicción, clasificación. Extracción de conocimiento y toma de decisiones. Aprendizaje automático: supervisado, no supervisado y reforzado. Datos y sociedad: investigación reproducible, modelos sesgados e implicaciones éticas.

Contenidos

Módulo 1. Científico/a de datos

- › Científico/a de Datos: concepto y alcance.
- › Competencias del perfil (técnicas y transversales).
- › Perfiles profesionales y áreas de actuación en el ecosistema de datos.
- › Lenguajes en ciencia de datos: panorama de SQL, R y Python (*uso típico y ventajas generales*).
- › Principales programas y herramientas del entorno de trabajo (*visión general, sin profundización*).

Módulo 2. Datos

- › Tipos y características de los datos (*estructurados y semiestructurados a nivel introductorio*).
- › Fuentes de datos habituales (archivos y bases de datos).
- › Calidad de los datos: criterios básicos (completitud, consistencia, validez) y su impacto.

Módulo 3. Etapas en Ciencia de Datos I: Extracción, transformación y carga (ETL)

- › Extracción: obtención de datos desde distintas fuentes.
- › Transformación: limpieza y preparación elemental.
- › Carga/Integración: conformación de un dataset base para análisis.
- › Registro simple del proceso (trazabilidad y reproducibilidad inicial).

Módulo 4 .Etapas en Ciencia de Datos II: Análisis exploratorio

- › Descriptores básicos y visualización inicial para conocer el conjunto de datos.
- › Identificación preliminar de patrones, valores faltantes y atípicos.
- › Formulación de primeras preguntas/hipótesis a partir del EDA.

Módulo 5 .Etapas en Ciencia de Datos II: Análisis exploratorio

- › Ideas generales de modelización (enfoques supervisados a nivel conceptual).
- › Predicción y clasificación: propósito y ejemplos introductorios.
- › Evaluación básica de resultados con métricas simples y lectura de resultados.

Módulo 6: Etapas en Ciencia de Datos IV: Segmentación, agrupamiento y toma de decisiones

- › Segmentación/Agrupamiento: objetivo y aplicaciones iniciales.
- › Extracción de conocimiento: síntesis de hallazgos y soporte a la decisión.
- › Comunicación de resultados, límites del análisis y consideraciones éticas y de reproducibilidad.


Bibliografía

Obligatoria


Material didáctico de producción institucional diseñado y desarrollado especialmente para cada módulo.

Planificación

Porcentaje estimativo por módulo según la cantidad y complejidad de contenidos y actividades:



Representación de porcentajes en semanas:



✓ Evaluación integradora

Metodología

A) Estrategias de enseñanza: Este espacio curricular fue diseñado según lo previsto en el Sistema Institucional de Educación a Distancia (SIED) de la UBP (Resolución MECCYT 197/2019), las características de los destinatarios, las necesidades de esta disciplina, competencias que se espera promover en esta asignatura y el perfil del egresado.

En relación con lo anterior, para llevar a cabo la enseñanza se cuenta con:

- › Contenidos y actividades de aprendizaje desarrollados en la plataforma virtual miUBP.
- › Material bibliográfico especialmente seleccionado.
- › Clases en video, en las que el docente expone contenidos que considera relevantes y que pueden ser visualizadas en cualquier momento.
- › Tutorías virtuales que implican diferentes espacios de interacción.

B) Materiales curriculares: Durante el cursado, se fomenta el estudio de los contenidos (presentados en diferentes soportes y lenguajes) que componen el programa, y la resolución de las actividades de aprendizaje. De esta forma, se introduce al alumno en los conceptos que se deben dominar en todo lo que respecta a la Introducción a la Ciencia de Datos. También, se invita a leer bibliografía que enriquece y profundiza dicho desarrollo. Por otra parte, se propone la resolución de actividades de aprendizaje tanto de carácter optativo como obligatorio que se encuentran debidamente identificadas en la plataforma. Algunas de ellas se centran en la apropiación de conceptos teóricos básicos de la asignatura y otras en la transferencia mediante un abordaje práctico a través del análisis de casos, ejercitaciones y situaciones problemáticas.

C) Modalidad de agrupamiento: En esta asignatura se proponen principalmente instancias de producción individual, en coherencia con los objetivos y contenidos a trabajar. De esta manera, el alumno puede desenvolverse en forma autónoma, reconociendo sus fortalezas y debilidades, a la vez que puede desarrollar sus propias estrategias de aprendizaje. Es importante destacar que para el estudio de la asignatura los alumnos pueden optar por agruparse libremente y resolver las actividades de aprendizaje planteadas.

D) Interacción: La comunicación con el docente tutor se realiza a través de los diferentes medios disponibles en la plataforma miUBP.

E) Formación Práctica: En lo que se refiere a la formación práctica se hace foco en la resolución de problemas que implique el uso de los contenidos estudiados en la asignatura contextualizados en situaciones que tengan que ver con la carrera.

Evaluación

La metodología de evaluación propuesta se presenta conforme al Reglamento Académico General de la UBP.

Cada instrumento de evaluación contiene sus criterios de evaluación explicitados y el puntaje otorgado a cada consigna.

En cuanto a los criterios de acreditación, la escala cuantitativa utilizada para evaluar es del 1 al 100 y el puntaje mínimo que se requiere para la aprobación es de 50.

Regularidad

Para alcanzar la condición de alumno regular usted deberá aprobar la Evaluación Integradora dentro de los plazos previstos para el cursado.

Si reprueba esta instancia podrá reelaborar la evaluación según los requerimientos del docente.

Examen Final

Deberá rendir, en condición de regular, una evaluación final que se realizará a través de un examen escrito integrador, presencial, en el periodo que disponga la Universidad.


MÓDULO 1

Microobjetivos

- › Reconocer el concepto de ciencia de datos, su alcance y su carácter interdisciplinario, para situarlo en relación con otros campos como la estadística y la informática y comprender su especificidad como campo de estudio y práctica profesional.
- › Identificar los distintos roles y perfiles profesionales del ecosistema de datos, para comprender las funciones, responsabilidades y áreas de actuación del/de la científico/a de datos y de otros perfiles afines dentro de organizaciones y proyectos.
- › Describir las competencias técnicas y transversales que conforman el perfil profesional del científico de datos, a fin de valorar la importancia del trabajo interdisciplinario y la toma de decisiones basada en datos.
- › Reconocer los lenguajes, herramientas y entornos de trabajo fundamentales de la ciencia de datos, para comprender su función general dentro del ciclo de vida del dato sin profundización técnica.
- › Analizar la noción de insight accionable y la dimensión ética y social de la ciencia de datos, con el objetivo de comprender cómo los datos pueden transformarse en conocimiento útil mediante prácticas responsables, reproducibles y socialmente situadas.
- › ingeniería informática de diseño gráfico de gestión de logística de empresas agropecuarias de negocios medio pequeños y nuevos medios

Contenidos

- Científico/A De Datos



Fuente: Freepik

¡Bienvenido/a al primer módulo de la materia!

Seguramente ha escuchado que la ciencia de datos es una de las profesiones más demandadas del siglo XXI, pero más allá de ese anuncio publicitario, aquí descubriremos qué

hace realmente un científico de datos y cómo puede convertirse en uno/a. A lo largo de estas páginas, exploraremos desde la definición del rol hasta las herramientas técnicas que forman el ecosistema actual de los datos.

- ***Científico/a de datos: concepto y alcance***

La ciencia de datos se define fundamentalmente como una metodología multidisciplinaria diseñada para inferir conocimientos accionables (*actionable insights*) a partir de grandes volúmenes de datos. No se trata simplemente de una rama de la estadística o la informática, sino de un campo que integra principios, procesos y técnicas para comprender fenómenos mediante el análisis automatizado de la información. En términos prácticos, consiste en realizar un trabajo de orientación analítica que requiere habilidades sustanciales de ingeniería de software para transformar datos en bruto en productos valiosos. Un científico de datos es, por tanto, un profesional capaz de extraer conocimiento de datos desordenados para guiar la toma de decisiones empresarial y social. De manera humorística, se le ha descrito como alguien que sabe más de estadística que cualquier ingeniero de software y más de ingeniería de software que cualquier estadístico.

El alcance de esta disciplina ha crecido exponencialmente debido al fenómeno de la “datificación”, que es el proceso de convertir en datos aspectos del mundo que nunca antes se habían cuantificado, desde nuestras redes sociales y lecturas hasta nuestro comportamiento al conducir. Esta disponibilidad masiva de información permite que la ciencia de datos actúe como el motor detrás de tareas cotidianas, como los motores de búsqueda web o los sistemas de recomendación. El objetivo último es la producción de creencias informadas por evidencia, eliminando la dependencia exclusiva en la intuición o en las “mejores prácticas” no probadas. A diferencia de la estadística tradicional, que a menudo se centra en modelos explicativos para muestras pequeñas, la ciencia de datos se enfoca primordialmente en la predicción y en el manejo de datos a gran escala.

Para entender el concepto plenamente, es necesario distinguir entre el simple uso de datos y la creación de un producto de datos. Un producto de datos adquiere su valor de la información misma y genera más datos como resultado, creando un bucle de retroalimentación donde el usuario contribuye al valor del producto. Por ejemplo, las recomendaciones de Amazon o las sugerencias de amistad en LinkedIn no son solo aplicaciones con datos, sino productos de datos impulsados por la ciencia de datos. En este contexto, el científico de datos actúa como un estratega que utiliza algoritmos bien estructurados para resolver problemas del mundo real, desde la optimización de inventarios hasta el diagnóstico médico.

- ***El alcance estratégico y las estrategias de exploración***

La ciencia de datos permite adoptar cuatro estrategias principales para interactuar con la realidad a través de la información:

1. ***Sondear la realidad:*** Se recolectan datos de forma pasiva o activa para responder preguntas asociativas; actualmente, la inclusión de la causalidad permite identificar relaciones de causa y efecto más allá de las simples correlaciones.

2. **Descubrimiento de patrones:** Utiliza la heurística de “dividir y conquistar” para hallar grupos naturales y estructuras ocultas en los datos, algo vital para segmentar clientes o perfiles de salud.
3. **Predicción de eventos futuros:** Busca construir modelos robustos que permitan tomar decisiones reactivas y proactivas ante sucesos venideros, como optimizar las tareas de una tienda minorista basándose en el clima y ventas históricas.
4. **Comprensión de la percepción humana:** Utiliza técnicas de procesamiento de lenguaje natural, visión por computadora y procesamiento de voz para extraer significado de datos no estructurados.

El alcance de estas estrategias se aplica típicamente en dos tipos de decisiones: aquellas donde se deben realizar “descubrimientos” dentro de los datos (como identificar nuevas tendencias de consumo) y decisiones que se repiten a escala masiva, donde incluso una pequeña mejora en la precisión analítica genera grandes beneficios económicos (como el marketing directo o la detección de fraudes). Por ello, un científico de datos debe ser capaz de descomponer un problema empresarial complejo en piezas que encajen con tareas de minería de datos conocidas, como la clasificación, regresión o agrupamiento.

- ***El insight accionable y la relación entre humanos y computadoras en la ciencia de datos***

Un pilar central del concepto de ciencia de datos es que el patrón extraído debe ser no obvio y útil. Si un experto humano puede crear el patrón fácilmente en su mente, no tiene sentido utilizar la ciencia de datos para “descubrirlo”. El término “insight” destaca que el patrón debe proporcionar información relevante y profunda que antes estaba oculta. Por su parte, el término “accionable” resalta que la organización debe tener la capacidad técnica y operativa de utilizar ese conocimiento para resolver el problema. Un modelo que prediga la fuga de clientes es inútil si la empresa no tiene un equipo o proceso para contactar a esos clientes a tiempo y ofrecerles incentivos para quedarse.

Desde esta perspectiva, la ciencia de datos puede entenderse como una asociación estratégica entre el profesional y la computadora. Mientras que las máquinas son excelentes para procesar volúmenes masivos de datos y cuantificar la relevancia de miles de variables, los seres humanos somos superiores para identificar qué aspectos del mundo real son pertinentes de recolectar y para formular adecuadamente el problema inicial.



Énfasis

El científico de datos aporta juicio, creatividad y conocimiento del dominio, mientras que la computadora automatiza la búsqueda de patrones mediante el aprendizaje automático.

Este proceso es inherentemente iterativo y exploratorio. No se trata de un ciclo de desarrollo de software tradicional, sino de una investigación donde los resultados de una etapa a menudo obligan a replantear la comprensión fundamental del problema original. Por esta razón, el científico de datos debe ser un comunicador efectivo, capaz de traducir jerga técnica en respuestas comerciales comprensibles para los interesados (*stakeholders*).

- **Cambios y consolidación del perfil profesional**

Históricamente, el campo emergió para enfrentar los desafíos de los datos masivos y desordenados que las herramientas estadísticas tradicionales no podían manejar. En la actualidad, el perfil del científico de datos se ha desplazado hacia el de un solucionador de problemas pragmático. Se ha utilizado la metáfora del “cazador de tesoros” para describir su labor: alguien que busca constantemente señales valiosas en el ruido de los datos, aceptando que el fallo en los modelos es una parte natural y frecuente del proceso de investigación y desarrollo.

Por otra parte, el alcance de la ciencia de datos no se limita a grandes corporaciones tecnológicas; se extiende a la medicina de precisión, la planificación de ciudades inteligentes, la justicia criminal y el deporte profesional. Es una disciplina que requiere no solo dominio técnico de lenguajes como Python, R o SQL, sino también una sólida base ética para manejar cuestiones de privacidad y sesgos algorítmicos en un mundo donde la toma de decisiones está cada vez más automatizada.

En este marco, la responsabilidad ética del científico de datos adquiere un carácter central, ya que los modelos y sistemas desarrollados no son neutrales y sus resultados pueden incidir de manera directa en decisiones que afectan a personas y colectivos. La utilización de datos históricos, frecuentemente atravesados por desigualdades y exclusiones, exige una mirada crítica que permita identificar, evaluar y mitigar posibles sesgos, así como reflexionar sobre los alcances y límites de la automatización. De este modo, la práctica de la ciencia de datos implica no solo producir soluciones técnicamente eficientes, sino también asumir una responsabilidad social orientada a garantizar un uso justo, transparente y contextualizado del conocimiento generado.

De esta manera, el perfil del científico de datos se caracteriza por ser una amalgama multidisciplinaria de habilidades que permiten transformar datos brutos en productos de conocimiento valiosos para la sociedad y las empresas. Un científico de datos eficiente es definido no solo como un técnico, sino como un estratega y un solucionador de problemas que utiliza algoritmos bien estructurados para proveer soluciones a retos del mundo real. Dada la complejidad de las tareas involucradas, que van desde la captura de información hasta la narración de historias basadas en evidencia, se reconoce que es difícil encontrar a una sola persona con todas las competencias requeridas, por lo que a menudo estos profesionales trabajan en equipos con roles complementarios.

Las competencias técnicas o *hard skills* representan la base operativa del perfil y se dividen en pilares fundamentales que abarcan las matemáticas, la informática y la gestión de infraestructura.

1. **Alfabetización en matemáticas y estadística:** El conocimiento matemático y estadístico constituye la “gramática” de la ciencia de datos, permitiendo que la información “hable coherentemente”. Esta competencia no requiere ser un genio matemático, sino alcanzar tres niveles de alfabetización: conocer qué técnicas existen (como el clustering), saber cómo aplicarlas y configurarlas mediante código, y poseer el criterio para elegir la técnica más adecuada para un problema específico. Los científicos/as de datos deben dominar tanto la estadística descriptiva para resu-

mir datos de manera sensata, como la estadística inferencial para probar hipótesis y asegurar que las conclusiones extraídas sean válidas y no meras fluctuaciones aleatorias. Es vital desarrollar una mentalidad de pensamiento crítico típica de las clases de estadística para ser extremadamente cuidadoso con las suposiciones que se hacen sobre los datos. Además, el auge del aprendizaje automático (machine learning) exige entender algoritmos de clasificación, regresión y aprendizaje profundo, tratando estos modelos como “cajas grises” de las cuales se comprende su funcionamiento interno y limitaciones sin necesidad de reimplementarlas desde cero constantemente.


2. **Programación, bases de datos y “hacking skills”:** La capacidad de escribir código limpio, eficiente y mantenible es lo que distingue al científico de datos de un analista tradicional. Las competencias en esta área incluyen:
 - › **Lenguajes de programación:** El dominio de Python y R es esencial. Python destaca por su versatilidad en tareas de ingeniería y producción, mientras que R es la herramienta por excelencia para análisis estadístico profundo y visualización.
 - › **Bases de datos y SQL:** Es prácticamente imposible avanzar en este campo sin dominar el lenguaje SQL, que permite manipular y extraer información de bases de datos relacionales, que siguen siendo el repositorio principal de la mayoría de las organizaciones.
 - › **Ingeniería de software:** El/la científico/a de datos debe realizar un trabajo de orientación analítica que requiere habilidades sustanciales de ingeniería de software para manejar datos masivos, lo que incluye el uso de sistemas de control de versiones como Git y entornos de desarrollo como Jupyter Notebooks.
3. **Captura, preparación y modelado de datos:** La mayor parte del tiempo de un proyecto (alrededor del 80%) se consume en la adquisición, limpieza y transformación de datos, tareas conocidas coloquialmente como data wrangling o munging. Esta competencia implica:
 - › **Extracción, transformación y carga (ETL):** Capacidad para buscar y consolidar datos de fuentes disparatadas, transformándolos en un formato común cohesivo para el análisis.
 - › **Minería de datos:** Habilidad para extraer y convertir datos no estructurados (como correos, imágenes o redes sociales) en información útil y estructurada.
 - › **Big Data:** Conocimiento de arquitecturas como Hadoop y Spark para procesar volúmenes de datos que exceden la capacidad de los sistemas tradicionales.
4. **Visualización de datos:** La visualización es crucial tanto para la exploración interna como para la comunicación de resultados. Un científico de datos debe actuar como un “escultor de datos”, eliminando el ruido y los valores atípicos para que otros puedan ver la “obra maestra” de información oculta. Esto requiere habilidades en el uso de bibliotecas como Matplotlib, Seaborn o D3.js para crear representaciones gráficas que cuenten una historia específica y no solo presenten números.

Asimismo, el valor del conocimiento técnico es nulo si el/la profesional no posee las habilidades interpersonales y estratégicas para aplicarlo de manera efectiva en un contexto organizacional.

1. **Comprensión del negocio y el dominio:** Esta competencia permite traducir una situación empresarial vaga (ej. “¿Por qué se van los clientes?”) en una pregunta de datos que pueda resolverse mediante algoritmos. El científico de datos debe entender el contexto real para identificar qué aspectos del mundo es relevante cuantificar, lo que requiere una estrecha colaboración con expertos del dominio. Además, implica ver los datos y la capacidad analítica como activos estratégicos clave de la organización en los que se debe invertir.
2. **Comunicación y narración basada en evidencia:** El éxito de un proyecto depende de la capacidad de comunicar la “historia” que cuentan los datos a audiencias con diversos niveles de conocimiento técnico. Esto incluye:
 - **Traducción de lenguajes:** Capacidad para cerrar la brecha entre el lenguaje técnico y el lenguaje de negocios, adaptando reportes y presentaciones para que sean comprensibles para ejecutivos y tomadores de decisiones.
 - **Storytelling:** Usar visualizaciones y narrativas concretas para asegurar que el impacto de los hallazgos no se pierda en la abstracción matemática.
3. **Ética y responsabilidad social:** Dado el impacto creciente de la disciplina en la vida privada y la justicia social, el/la científico/a de datos debe poseer una sólida base ética. Esto implica:
 - **Privacidad y legalidad:** Comprender las regulaciones sobre datos personales y manejar la información con integridad y consentimiento informado.
 - **Transparencia y equidad:** Asegurar que los modelos sean explicables y no perpetúen sesgos o discriminación ya presentes en los datos históricos.
 - **Responsabilidad:** Reconocer que los algoritmos operan de manera amoral y requieren supervisión humana constante para evitar consecuencias sociales negativas.
4. **Proactividad, curiosidad e iteración:** La ciencia de datos es una labor exploratoria más parecida a la investigación y desarrollo (I+D) que a la ingeniería tradicional. El/la profesional debe tener una mentalidad de “cazador de tesoros”, aceptando el fallo de los modelos como parte natural del proceso y persistiendo en la búsqueda de señales valiosas en el ruido. La proactividad para formular problemas y la disposición para el aprendizaje continuo son motores fundamentales en un campo que evoluciona rápidamente.

Un modelo conceptual útil para visualizar este perfil es el triángulo de la ciencia de datos, donde los vértices representan: las matemáticas/estadística, la programación/bases de datos y el conocimiento del dominio/negocio. La ubicación de un profesional dentro de este triángulo define su especialidad:

- › **Analista:** Se inclina hacia el dominio y los datos básicos, enfocándose en métricas clave.
- › **Machine learning engineer:** Se inclina hacia la programación y los modelos automáticos continuos.
- › **Decision scientist:** Se ubica en el centro-superior, combinando estadística profunda con necesidades estratégicas de decisión.



Fuente: Elaboración propia a partir de IA.



En el ecosistema de los datos, el título de científico de datos actúa a menudo como un término paraguas que abarca diversas especialidades, ya que es difícil encontrar a una sola persona con todas las competencias técnicas, estadísticas y de negocio requeridas. Debido a que la ciencia de datos es una disciplina multidisciplinaria, los profesionales suelen trabajar en equipos donde los roles se complementan para cubrir desde la captura de información hasta la toma de decisiones estratégicas.

A continuación, detallaremos los perfiles profesionales específicos y las áreas donde esta disciplina genera un impacto transformador. Aunque los títulos pueden variar significativamente entre empresas, la industria ha consolidado roles claros basados en el enfoque del trabajo y el “cliente” final (ya sea un humano que toma decisiones o una máquina que ejecuta procesos).

› **Analista de datos (data analyst)**

El/la analista de datos tiene como función principal tomar los datos de la empresa y ponerlos en manos de las personas adecuadas para facilitar el seguimiento de objetivos. Su trabajo se centra en la creación de tableros de control (dashboards) y reportes que permiten a los gerentes rastrear progresos semanales o desglosar métricas por regiones o productos. Aunque realizan una limpieza profunda de datos, su labor se enfoca menos en la interpretación estadística compleja y más en la entrega de información visualmente convincente que se actualice automáticamente sin errores.

› **Ingeniero/a de aprendizaje automático (*machine learning engineer*)**

Este perfil se asemeja más al de un/a desarrollador/a de software y su producto final está diseñado para el consumo de máquinas. El/la ingeniero de ML desarrolla modelos que deben correr continuamente en sistemas de producción, como los algoritmos de recomendación de Amazon o los sistemas de ranking de búsqueda en sitios de comercio electrónico. A diferencia de otros roles, sus entregables suelen ser APIs (Application Programming Interfaces), por lo que su código debe ser altamente eficiente, probado y escalable.

› **Científico/a de decisiones (*decision scientist*)**


El/la científico de decisiones es un especialista en convertir datos brutos en información que ayude a la alta dirección a elegir un camino bajo condiciones de incertidumbre. Este rol requiere una comprensión profunda de métodos matemáticos y estadísticos aplicados, como el diseño de experimentos o pruebas A/B, para determinar si un cambio en un producto (como un nuevo diseño de página web) es realmente efectivo o solo fruto del azar. Sus resultados se entregan habitualmente en forma de recomendaciones estratégicas apoyadas por visualizaciones potentes.

› **Ingeniero/a de datos (*data engineer*)**

Es el/la arquitecto/a del sistema, se encarga de que la infraestructura permita que el flujo de información sea accesible para los demás. Su enfoque está en el mantenimiento de las bases de datos a gran escala y en la construcción de ductos de datos (pipelines) para la extracción, transformación y carga (ETL) de información. Sin el trabajo del ingeniero de datos, el científico de datos pasaría meses intentando simplemente acceder a la información antes de poder analizarla.

En este marco, emergen perfiles complementarios y especializados que cumplen funciones diferenciadas dentro del campo de la ciencia de datos, entre los que se destacan el/la *analista de inteligencia de negocios (BI Analyst)*, quien utiliza herramientas como Excel o Tableau para elaborar reportes de métricas clave, generalmente con menor énfasis en programación avanzada o en modelos predictivos, y el/la *científico/a de investigación (research scientist)*, que suele contar con formación doctoral y se dedica al desarrollo de nuevos algoritmos y metodologías de vanguardia que luego pueden ser aplicados por el resto de la organización.

- **Jerarquías y trayectorias profesionales**



Fuente: Elaboración propia a partir de IA.

La progresión en la carrera de ciencia de datos no solo implica ganar conocimiento técnico, sino también madurez en la resolución de problemas y liderazgo.

- › **Junior Data Scientist:** Es capaz de completar tareas específicas bajo una dirección clara, como aplicar un algoritmo de agrupamiento para segmentar clientes basándose en sus compras.
- › **Senior Data Scientist:** No solo ejecuta tareas, sino que identifica qué problemas deben resolverse a continuación. Posee autonomía técnica y es el referente cuando otros tienen dificultades.
- › **Principal Data Scientist / Technical Lead:** Actúa como un mentor/a y estratega técnico. Es el/la encargado/a de decidir qué arquitectura de modelos es más viable para un proyecto de largo plazo y de resolver los problemas técnicos más espinosos que bloquean al equipo.
- › **Gerente de Ciencia de Datos:** Decide la estrategia del equipo, gestiona el presupuesto, contrata personal y actúa como puente de comunicación entre los expertos técnicos (“techies”) y los ejecutivos (“suits”).

- **Ámbitos de actuación y principales aplicaciones**

La ciencia de datos es ubicua y sus estrategias de exploración (sondeo de la realidad, descubrimiento de patrones y predicción) se aplican en casi todos los sectores de la sociedad.

› *Marketing, ventas y comercio electrónico*

Es el área de mayor aplicación. Las empresas utilizan la segmentación de clientes (clustering) para crear “personas” o perfiles de consumidores basados en datos reales en lugar de intuiciones. Un caso icónico es el de Walmart, que analiza tendencias en redes sociales para introducir nuevos productos y utiliza datos históricos para optimizar sus inventarios ante eventos climáticos, como huracanes. Por otro lado, los sistemas de recomendación de plataformas como Netflix o Amazon generan productos de datos que aprenden del comportamiento del usuario para ofrecerle contenido personalizado, aumentando drásticamente la retención y las ventas.

› *Finanzas y operaciones*

En el sector financiero, se emplea para la detección de fraudes en tiempo real analizando la actividad de las tarjetas de crédito. También es fundamental en la calificación crediticia (*credit scoring*) para decidir a quién otorgar un préstamo y en la optimización de procesos internos, donde el uso de analítica puede reducir tiempos de respuesta de semanas a solo unas pocas horas.

› *Salud y medicina de precisión*

La ciencia de datos está revolucionando la medicina mediante el análisis de genomas para diseñar fármacos específicos para cada individuo. Los sensores portátiles (*wearables*) permiten el monitoreo continuo de signos vitales, generando datos que, al ser analizados, permiten predecir crisis de salud antes de que ocurran o ajustar tratamientos de manera personalizada según la respuesta biológica del paciente.

› *Gobierno y ciudades inteligentes (smart cities)*

Los gobiernos utilizan la ciencia de datos para mejorar la planificación urbana y los servicios públicos. En las “ciudades inteligentes”, se integran datos de tráfico, clima y sensores viales para controlar semáforos en tiempo real, priorizar el transporte público y optimizar la recolección de residuos o el consumo energético de los edificios públicos. También se aplica en la seguridad pública para predecir puntos calientes de delincuencia, aunque esto último ha generado debates éticos importantes.

› *Deporte profesional*

Inspirado por el fenómeno de “Moneyball”, franquicias deportivas de todo el mundo emplean analítica de datos para el reclutamiento de jugadores, evaluando métricas de rendimiento que los cazatalentos tradicionales suelen pasar por alto.

› **Lenguajes en ciencia de datos: panorama de SQL, R y Python**

En el ecosistema de la ciencia de datos, la elección del lenguaje de programación es una decisión estratégica, ya que cada uno ofrece diferentes capacidades para enfrentar el ciclo de vida del dato, desde la extracción hasta la modelización avanzada. Aunque herramientas gráficas como Excel o Tableau son útiles para el análisis de datos tabulares limpios, la ciencia de datos requiere lenguajes de programación robustos para manejar datos desordenados, automatizar procesos complejos y realizar análisis que no están predefinidos en paquetes comerciales. A continuación, se detalla el panorama de los tres lenguajes fundamentales: Python, R y SQL.

- **Python**



Fuente: <https://www.python.org/>

Python se ha consolidado como el lenguaje más popular en la industria debido a su versatilidad y a una sintaxis clara que se asemeja al inglés, lo que facilita el aprendizaje para principiantes y la legibilidad para expertos. Fue creado por Guido van Rossum en 1991 como un lenguaje de propósito general, lo que permite que un científico de datos desarrolle no solo el modelo analítico, sino también las interfaces y sistemas estructurales que lo rodean.

Se caracteriza por ser un lenguaje multiparadigma, ya que soporta cuatro estilos de programación complementarios. Permite trabajar desde un enfoque funcional, especialmente adecuado para el procesamiento paralelo; un enfoque imperativo, eficiente para la manipulación directa de estructuras de datos; un enfoque orientado a objetos, que favorece la reutilización y organización del código; y un enfoque procedimental, basado en iteraciones secuenciales paso a paso. Esta flexibilidad lo convierte en una herramienta adaptable a distintos tipos de problemas y contextos de desarrollo.

Asimismo, suele describirse como el “segundo mejor lenguaje para cualquier tarea”. Esta expresión alude a que, si bien existen lenguajes más especializados para tareas específicas, Python se destaca cuando es necesario integrar múltiples disciplinas —como matemáticas, ingeniería de software y visualización de datos— dentro de un mismo proyecto, ofreciendo un equilibrio eficaz entre potencia y simplicidad.

Una de las principales fortalezas de Python reside en su amplio ecosistema de bibliotecas científicas, que permiten delegar el denominado “trabajo pesado” a librerías consolidadas y optimizadas. Entre ellas, Pandas ofrece estructuras de datos como el DataFrame, fundamentales para la manipulación ágil de datos tabulares y series temporales; NumPy constituye la base de la computación científica, facilitando la gestión eficiente de arreglos multidimensionales y operaciones de álgebra lineal; y Scikit-Learn se posiciona

como la librería estándar para tareas de minería de datos y aprendizaje automático tradicional, como clasificación, regresión y clustering. A esto se suman herramientas como Matplotlib y Seaborn, orientadas a la creación de gráficos y visualizaciones, y Keras junto con TensorFlow, que resultan clave para el desarrollo y entrenamiento de modelos de deep learning y redes neuronales.

Finalmente, al tratarse de un lenguaje de código abierto con una comunidad amplia y activa, Python cuenta con un sólido sistema de soporte. Esto facilita el acceso a documentación, tutoriales y espacios de consulta, lo que reduce significativamente las barreras para resolver problemas técnicos y aprender de manera autónoma.

- **R: el lenguaje de los estadísticos**



Fuente: <https://www.r-project.org/>

A diferencia de Python, que nació para la ingeniería de software, R fue diseñado específicamente por y para estadísticos. Tiene sus raíces en el lenguaje S, desarrollado en Bell Labs en la década de 1970, y sigue siendo la herramienta preferida en la academia y en aquellos contextos que demandan análisis estadísticos de alto rigor matemático.

En cuanto a su uso típico, R se destaca especialmente en el análisis exploratorio de datos y en el modelado estadístico avanzado. Ofrece una potencia notable para la visualización nativa de datos y para la aplicación de modelos estadísticos complejos, lo que lo convierte en una opción privilegiada para la investigación científica. Asimismo, mediante herramientas como R Markdown, permite la generación de informes reproducibles que integran código, texto y resultados, facilitando la comunicación clara y transparente de los hallazgos a distintos grupos de interés.

Entre sus ventajas generales, sobresale su alto grado de especialización estadística. El repositorio CRAN alberga una vasta colección de paquetes que cubren prácticamente cualquier nicho estadístico imaginable, muchos de los cuales aún no cuentan con equivalentes directos en Python. A ello se suma la calidad de sus capacidades de visualización: librerías como ggplot2 permiten construir gráficos con una estética profesional y una gran flexibilidad conceptual, especialmente adecuada para representar datos multidimensionales.

No obstante, frente a Python, R presenta algunas desventajas. Si bien es sumamente eficaz para tareas estadísticas, suele ser percibido como más complejo desde el punto de vista sintáctico por quienes provienen del ámbito de la informática. Además, puede resultar menos eficiente en el manejo de memoria cuando se trabaja con conjuntos de datos masivos y en la puesta en producción de algoritmos que requieren ejecución en tiempo real.



Fuente: Freepik

- **SQL: el estándar para la interacción con datos**

El Structured Query Language (SQL) es el lenguaje universal utilizado para interactuar con bases de datos relacionales. Constituye una habilidad indispensable para cualquier científico de datos, ya que la mayoría de los datos organizacionales residen en sistemas de gestión de bases de datos relacionales (RDBMS) basados en el modelo de Edgar F. Codd.

En cuanto a su uso típico, SQL resulta fundamental en los procesos de extracción y carga de datos (ETL). Permite filtrar información, unir tablas y resumir volúmenes que pueden alcanzar cientos de millones de registros antes de trasladarlos a lenguajes como Python o R, donde se realiza un análisis más profundo. Asimismo, facilita la realización de consultas exploratorias orientadas al descubrimiento, lo que posibilita responder de manera ágil a preguntas de negocio concretas, por ejemplo, identificar a los clientes más rentables en una determinada región sin necesidad de desarrollar scripts complejos.

Entre sus ventajas generales y en el marco de las tendencias modernas, se destaca la posibilidad de realizar machine learning directamente dentro de la base de datos. Muchas plataformas actuales, como SQL Server, Oracle o BigQuery, permiten ejecutar algoritmos de aprendizaje automático utilizando SQL, lo que evita el traslado de grandes volúmenes de datos hacia servidores externos, mejorando tanto la seguridad como la velocidad de procesamiento. A esto se suma la independencia del almacenamiento que ofrece el lenguaje, ya que el usuario puede definir qué datos necesita sin preocuparse por la forma en que están organizados físicamente o indexados en el servidor. Finalmente, su ubicuidad refuerza su relevancia: incluso en entornos de Big Data, como Spark o Hive, se emplean lenguajes de consulta similares a SQL para facilitar la exploración de grandes volúmenes de datos distribuidos.

- › **Elección de lenguajes según perfiles y entornos de trabajo**

La decisión de qué lenguaje utilizar depende a menudo del perfil del profesional y del entorno de trabajo. Mientras que un ingeniero de aprendizaje automático preferirá Python por su capacidad de integración en sistemas de producción, un científico de decisiones podría optar por R para realizar un análisis estadístico ad-hoc riguroso.

En la comparación entre Python y R, históricamente se ha señalado que Python se orientaba al desarrollo de software y R al análisis estadístico. No obstante, en la actualidad

existe una creciente paridad de capacidades entre ambos lenguajes. Python suele destacarse en el trabajo con conjuntos de datos de gran escala y en tareas de machine learning productivo, mientras que R continúa liderando en la elaboración de reportes estadísticos y en la visualización con fines académicos. Por su parte, SQL no compite con Python ni con R, sino que cumple un rol complementario indispensable. Un flujo de trabajo típico comienza con consultas en SQL para extraer y preparar los datos necesarios, y continúa con scripts en Python o R destinados al procesamiento, análisis y modelización.

En este sentido, un científico de datos con formación integral debe dominar SQL para la extracción de datos y ser competente en al menos uno de los lenguajes analíticos (Python o R) para realizar el procesamiento y la modelización. Además, existen lenguajes emergentes como Julia (valorado por su velocidad de ejecución) y Scala (esencial para infraestructuras de Big Data como Spark), que los profesionales pueden adoptar según la especialidad técnica y del recorrido profesional que se desee construir.

▸ Principales programas y herramientas del entorno de trabajo

El entorno de trabajo de un científico de datos moderno no se limita a un único programa, sino que constituye un ecosistema integrado de herramientas diseñadas para maximizar la productividad, asegurar la reproducibilidad y permitir el manejo de datos a gran escala. Este conjunto de herramientas, conocido coloquialmente como la “caja de herramientas” (*toolbox*), es un ingrediente esencial para el éxito y el rendimiento mejorado en la disciplina.

A continuación, se presenta una visión general detallada de los principales programas y plataformas que conforman este ecosistema, excluyendo los lenguajes base ya tratados.

<i>Categoría</i>	<i>Herramienta o tecnología</i>	<i>Función</i>	<i>Características</i>
Distribuciones y gestores de paquetes	Anaconda	Distribución integrada para ciencia de datos	Agrupar Python, Jupyter y bibliotecas clave como NumPy y Pandas en una sola instalación. Proporciona un entorno aislado que no interfiere con otros programas y facilita la configuración inicial, especialmente para principiantes.
	Conda	Gestión de paquetes y entornos virtuales	Permite crear entornos virtuales independientes para distintos proyectos, evitando conflictos entre versiones de bibliotecas. Verifica la compatibilidad entre paquetes antes de realizar cambios, siendo más eficiente que otros gestores.

Entornos interactivos y notebooks	Jupyter Notebook	Desarrollo interactivo y programación literaria	Funciona en el navegador y organiza el trabajo en celdas ejecutables de forma independiente. Facilita la experimentación, el ajuste de modelos y el storytelling basado en evidencia, integrando código, texto y gráficos.
	Google Colab	Notebook en la nube	No requiere instalación local y permite utilizar servidores de Google, incluyendo acceso gratuito a GPUs. Facilita el trabajo colaborativo mediante la posibilidad de compartir cuadernos como documentos en línea.
	IPython	Intérprete interactivo avanzado	Potencia a Jupyter con funciones “mágicas” que permiten automatizar tareas, depurar código y explorar objetos de forma más fluida que el intérprete estándar de Python.
Bibliotecas fundamentales	Pandas	Manipulación y análisis de datos tabulares	Introduce el DataFrame, similar a una hoja de cálculo avanzada, que permite limpiar, filtrar, agrupar y transformar grandes volúmenes de datos de manera eficiente.
	NumPy y SciPy	Cómputo científico y matemático	NumPy permite operaciones rápidas sobre grandes arreglos de datos. SciPy amplía estas capacidades con algoritmos para optimización, estadística y procesamiento de señales.
	Scikit-learn	Aprendizaje automático tradicional	Biblioteca principal para clasificación, regresión y clustering. Se destaca por su interfaz uniforme, que facilita cambiar entre distintos modelos.

	Matplotlib y Seaborn	Visualización de datos	Matplotlib es la base para gráficos estáticos. Seaborn se construye sobre ella y permite generar visualizaciones más complejas y atractivas con menos código.
Ingeniería y producción	IDEs (PyCharm, Spyder, VS Code)	Desarrollo de proyectos de gran escala	Diseñados para trabajar con múltiples archivos, depurar sistemas complejos y realizar pruebas automatizadas, a diferencia de los notebooks orientados a la experimentación.
	Git y GitHub	Control de versiones y colaboración	Git permite registrar cambios y recuperar versiones anteriores del código. GitHub aloja los repositorios en la nube y facilita el trabajo colaborativo y la revisión de código.
	Docker	Contenerización de aplicaciones	Empaqueta el código junto con sus dependencias para asegurar que funcione de la misma manera en distintos entornos, evitando inconsistencias entre desarrollo y producción.
Big Data y almacenamiento	Hadoop	Procesamiento distribuido de grandes volúmenes de datos	Utiliza el paradigma MapReduce para dividir tareas en subtarefas que se ejecutan en paralelo sobre múltiples computadoras.
	Spark	Cómputo distribuido eficiente	Alternativa más rápida y moderna a Hadoop, permite análisis en tiempo real y aprendizaje automático a gran escala con mayor eficiencia.
	Bases de datos NoSQL	Almacenamiento de datos no estructurados	Sistemas como MongoDB, Cassandra o HBase ofrecen esquemas flexibles y alta escalabilidad para datos que no se ajustan a tablas rígidas.

Nube y herramientas complementarias	AWS, Azure, GCP	Infraestructura en la nube	Proveen servidores remotos con gran capacidad de procesamiento que se pueden alquilar bajo demanda, según las necesidades del proyecto.
	Excel y Tableau	Análisis y visualización	Excel sigue siendo clave para análisis rápidos, mientras que Tableau permite crear visualizaciones ejecutivas de alta calidad conectadas a bases de datos.
	APIs	Integración de sistemas	Permiten que los modelos de datos se comuniquen con otros sistemas, como aplicaciones web que consultan modelos de recomendación en tiempo real.



Énfasis

La elección de la herramienta depende de la fase del proyecto; se suele comenzar experimentando en un Jupyter Notebook con Pandas, para luego pasar a un IDE con Git y Docker cuando el modelo está listo para integrarse en un sistema de producción.



Actividad

Dando por finalizado el desarrollo del contenido del módulo, lo/a invitamos a trabajar con las actividades pertenecientes al módulo. Tenga presente que estaremos disponibles a través del espacio tutorial para que Ud. canalice sus dudas y comentarios.

MÓDULO 1 | GLOSARIO

Algoritmo: Conjunto finito y ordenado de instrucciones que permiten resolver un problema o realizar una tarea específica. En ciencia de datos, los algoritmos se utilizan para analizar datos, encontrar patrones o realizar predicciones.

Análisis exploratorio de datos (EDA): Etapa inicial del trabajo con datos que consiste en describir, resumir y visualizar un conjunto de datos para comprender su estructura, detectar valores atípicos, datos faltantes y formular primeras preguntas o hipótesis.

Aprendizaje automático (Machine Learning): Área de la inteligencia artificial que desarrolla modelos capaces de aprender patrones a partir de datos y realizar predicciones o decisiones sin ser programados explícitamente para cada caso.

Aprendizaje supervisado: Tipo de aprendizaje automático en el que el modelo se entrena con datos etiquetados, es decir, con ejemplos que incluyen la respuesta correcta (por ejemplo, clasificación y regresión).

Aprendizaje no supervisado: Tipo de aprendizaje automático en el que se analizan datos sin etiquetas, con el objetivo de descubrir estructuras ocultas, grupos o patrones (por ejemplo, clustering o agrupamiento).

Aprendizaje por refuerzo: Enfoque de aprendizaje automático en el que un agente aprende mediante prueba y error, recibiendo recompensas o penalizaciones según sus acciones.

Base de datos relacional: Sistema de almacenamiento de datos organizado en tablas relacionadas entre sí mediante claves. Se accede generalmente mediante el lenguaje SQL.

Big Data: Conjunto de tecnologías y enfoques destinados al almacenamiento y procesamiento de datos caracterizados por gran volumen, velocidad y variedad, que exceden las capacidades de los sistemas tradicionales.

Ciencia de datos: Disciplina interdisciplinaria que combina estadística, programación y conocimiento del dominio para extraer conocimiento accionable a partir de datos y apoyar la toma de decisiones.

Clustering (agrupamiento): Técnica de aprendizaje no supervisado que busca agrupar observaciones similares entre sí sin contar con etiquetas previas.

Datos: Representación simbólica de hechos, mediciones u observaciones del mundo real que pueden ser almacenados y analizados.

Datos estructurados: Datos organizados en un formato fijo, como tablas con filas y columnas, típicos de bases de datos relacionales.

Datos no estructurados: Datos que no siguen un esquema predefinido, como textos, imágenes, audio o video.

ETL (extracción, transformación y carga): Proceso que consiste en obtener datos desde distintas fuentes, limpiarlos y transformarlos, e integrarlos en un dataset listo para el análisis.

Ingeniería de datos: Área encargada de diseñar, construir y mantener la infraestructura necesaria para almacenar, procesar y disponibilizar datos de forma confiable.

Insight accionable: Patrón o conocimiento extraído de los datos que es relevante, no trivial y puede ser utilizado efectivamente para tomar decisiones o ejecutar acciones concretas.

Lenguaje SQL: Lenguaje estándar para consultar, filtrar, combinar y resumir datos almacenados en bases de datos relacionales.

Modelo: Representación matemática o computacional que describe relaciones en los datos y permite realizar predicciones o inferencias.

Notebook: Documento interactivo que combina texto, código ejecutable y resultados (gráficos, tablas), utilizado ampliamente en ciencia de datos para análisis exploratorio y reproducible.

Producto de datos: Sistema o aplicación cuyo valor principal proviene de los datos y los modelos analíticos que utiliza, y que suele generar nuevos datos a partir de su uso.

Programación reproducible: Práctica que permite que un análisis pueda ser ejecutado nuevamente obteniendo los mismos resultados, mediante el uso de notebooks, control de versiones y registro de configuraciones.

Regresión: Técnica de aprendizaje supervisado utilizada para predecir valores numéricos continuos.

Sesgo algorítmico: Distorsión sistemática en los resultados de un modelo causada por datos incompletos, desbalanceados o decisiones de diseño, que puede generar resultados injustos o discriminatorios.

Storytelling con datos: Proceso de comunicar hallazgos analíticos mediante narrativas claras apoyadas en visualizaciones, orientadas a la toma de decisiones.

Visualización de datos: Representación gráfica de la información (gráficos, diagramas, mapas) que facilita la comprensión, exploración y comunicación de los datos.

MÓDULO 1 | ACTIVIDADES



Actividad

ACTIVIDAD N° 1:

Reconociendo el rol del científico/a de datos

Lea atentamente la siguiente situación:

Una empresa de comercio electrónico observa que, aunque la cantidad de visitas a su sitio web crece mes a mes, las ventas no aumentan en la misma proporción. La dirección solicita entender qué está ocurriendo y qué acciones podrían tomarse para mejorar los resultados.

A partir de lo estudiado en este módulo:

1. Explique brevemente por qué este problema puede abordarse desde la ciencia de datos.
2. Indique qué tipo de conocimiento o “insight accionable” podría resultar útil en este caso.
3. Describa, en términos generales, el rol que cumpliría un/a científico/a de datos en esta situación.



Recomendaciones

No se espera una respuesta técnica ni el uso de herramientas específicas. En esta actividad, el foco está en la comprensión conceptual del rol y del valor de los datos en la toma de decisiones.



Actividad

ACTIVIDAD N° 2:

Perfiles profesionales en el ecosistema de datos

A continuación se presentan distintas tareas vinculadas al trabajo con datos:

- › Construir un tablero con indicadores mensuales de ventas.
- › Diseñar un sistema que procese millones de registros diarios y los deje listos para análisis.
- › Desarrollar un modelo que recomiende productos de forma automática.
- › Evaluar si un cambio en una página web produjo un impacto real en el comportamiento de los usuarios.

Para cada tarea:

1. Indique cuál de los perfiles estudiados en el módulo considera más adecuado para llevarla adelante.
2. Justifique brevemente su elección.



Recomendaciones

Utilice los perfiles analista de datos, ingeniero/a de datos, ingeniero/a de aprendizaje automático y científico/a de decisiones como referencia.



Actividad

ACTIVIDAD N° 3:

Ética y responsabilidad en ciencia de datos

Lea el siguiente enunciado:

“Los algoritmos toman decisiones objetivas porque se basan en datos.”

1. ¿Está de acuerdo con esta afirmación? Justifique su respuesta utilizando los conceptos desarrollados en el módulo.
2. Mencione al menos un ejemplo en el que un modelo pueda producir resultados sesgados.
3. Investigue y explique por qué la supervisión humana es necesaria en proyectos de ciencia de datos.

MÓDULO 2

Microobjetivos

- › Reconocer el concepto de dato en ciencia de datos como una abstracción del mundo real, identificando sus supuestos, límites y posibles sesgos de origen para comprender su carácter no neutro.
- › Interpretar la estructura básica de un dataset, distinguiendo entidades (filas) y atributos (columnas) dentro de una matriz de datos, a fin de comprender cómo se organiza la información para su análisis.
- › Diferenciar los principales tipos de datos (estructurados y semiestructurados) y las fuentes de datos comunes en ciencia de datos, para comprender sus características generales y su rol en las distintas etapas del proceso analítico.
- › Analizar la calidad de los datos a partir de criterios básicos como completitud, consistencia y validez, para comprender la importancia del principio GIGO y su impacto en el análisis y la modelización a partir de situaciones problemáticas simples.
- › Identificar problemas frecuentes presentes en datos reales, como valores faltantes, duplicados, inconsistencias y valores atípicos, para establecer su vinculación con las etapas posteriores del proceso de ciencia de datos, incluyendo la preparación de datos, el análisis exploratorio y la toma de decisiones.

Contenidos

- **Datos**



Fuente: Freepik

- **Introducción: Los datos y sus características principales**

- › *El concepto de dato en ciencia de datos*

En su forma más básica, un dato es una abstracción o una medida tomada de una entidad del mundo real, ya sea una persona, un objeto o un evento. La ciencia de datos se encarga de integrar algoritmos y procesos para analizar estos datos y extraer conocimientos accionables a partir de ellos. Un conjunto de datos o *dataset* consiste en información relacionada con una colección de entidades, donde cada entidad se describe mediante un conjunto de atributos.

En este sentido, el dato puede entenderse como una abstracción o medida tomada de la realidad, pero no como una descripción objetiva y total de ella. Por el contrario, se trata siempre del resultado de decisiones humanas acerca de qué aspectos cuantificar y qué categorías o medidas utilizar. Por ello, los datos constituyen representaciones parciales y situadas de los fenómenos que buscan describir; como suele señalarse en el campo, “el mapa no es el territorio”, aunque debe conservar una estructura similar para resultar útil en el análisis.

Desde el punto de vista de su organización, un *dataset* es una colección de información correspondiente a una serie de entidades, donde cada una se describe mediante distintos atributos. En la práctica profesional, esta información se representa habitualmente en forma de una matriz de datos, conocida como *analytics record* o registro analítico:

- › *Filas ()*: representan las entidades individuales y reciben nombres como instancias, ejemplos, casos, registros, objetos o muestras.
- › *Columnas ()*: representan las características observadas y se denominan atributos, variables, dimensiones, campos o features.

Cada instancia puede interpretarse, desde un punto de vista matemático, como un vector de características (*feature vector*), es decir, una lista de valores numéricos de longitud fija que habilita la aplicación de herramientas propias de la geometría y del álgebra lineal para su análisis.

› *De los datos al conocimiento accionable (“actionable insights”)*

La ciencia de datos se orienta a transformar grandes volúmenes de información en conocimiento accionable (*actionable insights*), integrando algoritmos y procesos capaces de extraer patrones útiles y no evidentes. Su objetivo último es la construcción de creencias fundamentadas en evidencia que sirvan como base para la toma de decisiones. En este marco, se busca producir lo que se denomina conocimiento accionable, una noción que combina dos dimensiones complementarias. Por un lado, el *insight* o percepción implica que el patrón identificado aporta información relevante que no resulta evidente a simple vista. Por otro lado, el carácter *accionable* supone que la organización cuenta con la capacidad técnica y operativa necesaria para utilizar ese conocimiento con el fin de resolver un problema concreto o mejorar un proceso determinado.

El creciente protagonismo de este enfoque se vincula con el fenómeno de la *datificación*, entendido como el proceso tecnológico de convertir en datos aspectos del mundo que nunca antes se habían cuantificado. Esto incluye desde comportamientos personales (libros que leemos o rutas de conducción) hasta señales generadas por maquinaria industrial y registros de actividad web que, en otros contextos, eran ignorados o descartados. La datificación amplía así el universo de información disponible y redefine qué dimensiones de la realidad pueden ser analizadas computacionalmente.

Para que estos datos puedan ser procesados por los algoritmos, es necesario clasificar sus atributos según el tipo de medición que admiten:

- › **Númericos (continuos):** permiten operaciones aritméticas y medidas de tendencia central como la media.
- › **Catagóricos (nominales/ordinales):** representan categorías discretas, si tienen un orden natural (como “bajo, medio, alto”) son ordinales, y si no lo tienen (como nombres o colores) son nominales.



La clave del éxito en la ciencia de datos suele radicar en la ingeniería de características, que consiste en identificar o crear los atributos derivados correctos que realmente logren capturar la lógica del problema que se intenta resolver.

› **Datos estructurados**

Los datos estructurados representan la piedra angular de la gestión de información tradicional y son el formato predilecto para la fase inicial de análisis en la ciencia de datos debido a su orden inherente. A continuación, se amplían detalladamente sus conceptos, características y ejemplos fundamentales.

› **Concepto y estructura tabular**

Desde el punto de vista conceptual, los datos estructurados son aquellos que se organizan en un formato tabular o matricial de dimensión $n \times m$, donde la información se descompone en atributos naturales. Esta estructura se basa en dos ejes principales:

- › **Filas (instancias):** cada fila representa una entidad o registro único (un cliente, una transacción, un sensor).
- › **Columnas (atributos):** cada columna contiene una característica específica de las instancias, como el nombre, la fecha o un valor numérico.

Este formato es ideal para la ciencia de datos porque permite que cada fila funcione como un vector de características (*feature vector*), facilitando la aplicación directa de herramientas del álgebra lineal, la estadística y los algoritmos de aprendizaje automático.

El marco teórico que sustenta este tipo de organización fue propuesto por Edgar F. Codd en 1970 a través de su *modelo relacional*, el cual marcó un hito al separar la forma en que los datos se almacenan físicamente de la forma en que los usuarios los consultan. Gracias a esta independencia de los datos, es posible extraer información mediante consultas declarativas sin necesidad de conocer la ubicación física de los archivos en el sistema. Asimismo, el modelo relacional incorpora el principio de normalización, que permite vincular tablas a través de claves comunes, reduciendo la redundancia y asegurando una interconexión lógica y consistente entre los datos.

Desde el punto de vista técnico, los datos estructurados se caracterizan por:

- › **Esquema rígido (schema-on-write):** a diferencia de otros tipos de datos, los estructurados requieren que el esquema se defina con antelación. Esto implica preestablecer el nombre de cada columna y su tipo de dato (entero, cadena de texto, fecha, etc.) antes

de poder ingresar cualquier información. En este modelo, todas las instancias deben poseer el mismo conjunto de atributos, lo que garantiza una uniformidad total en el dataset.

- › **Consistencia y transaccionalidad:** las bases de datos estructuradas están diseñadas para soportar operaciones transaccionales complejas con un alto nivel de integridad. Esto significa que, si una parte de una operación falla, el sistema puede revertir los cambios (*rollback*), asegurando que la base de datos no quede en un estado inconsistente. Por este motivo, los datos estructurados son el formato estándar para datos transaccionales, como ventas, pagos con tarjeta de crédito o emisiones de facturas.
- › **Facilidad de manipulación vía SQL:** otra de sus ventajas centrales es la facilidad de manipulación mediante el Lenguaje de Consulta Estructurado (SQL), un estándar internacional que permite gestionar grandes volúmenes de datos de manera eficiente. Las operaciones fundamentales que permite son:
 - › SELECT: recuperar datos específicos bajo ciertas condiciones.
 - › INSERT / UPDATE: agregar nuevos registros o modificar los existentes.
 - › DELETE: eliminar filas específicas de manera controlada.
 - › JOIN: combinar datos de múltiples tablas basándose en relaciones existentes.

En cuanto a los formatos más habituales, los datos estructurados suelen almacenarse en sistemas de gestión de bases de datos relacionales (RDBMS), que son servidores diseñados para manejar volúmenes de información que exceden la capacidad de una computadora común. Los proveedores líderes incluyen Oracle, MySQL, SQL Server, SQLite y PostgreSQL. También son frecuentes los archivos de texto plano delimitado, que resultan legibles por humanos y facilitan su creación y manipulación mediante scripts. El formato CSV (Comma Separated Values) utiliza un encabezado para definir los campos y comas para separar los valores de cada registro. Asimismo, existen archivos delimitados por tabulaciones u otros caracteres personalizados, como el símbolo pipe (|). Las hojas de cálculo, como Excel, constituyen otro ejemplo frecuente, ya que proporcionan contenido altamente formateado donde se puede especificar cada aspecto de la información. Aunque son excelentes para análisis simples y visualización rápida, para proyectos de ciencia de datos a menudo se recomienda convertirlos a formatos más livianos como CSV para agilizar el procesamiento computacional.

Finalmente, pese al auge del Big Data y los datos no estructurados, los datos estructurados siguen siendo el “backbone” de la inteligencia de negocios (BI). En el flujo de trabajo de un científico de datos, casi cualquier dato de otra fuente, como texto libre, registros de servidores o interacciones en redes sociales, debe ser extraído y transformado en un formato estructurado antes de que pueda ser analizado o utilizado para entrenar modelos de aprendizaje automático.

› **Datos semiestructurados**

Los datos semiestructurados representan un puente fundamental en la ciencia de datos moderna, situándose entre la rigidez de las tablas tradicionales y la falta total de orden de los datos no estructurados. A diferencia de las bases de datos relacionales, donde cada fila debe cumplir estrictamente con un esquema de columnas fijo, el formato semiestructurado permite que el conjunto de atributos esté encapsulado dentro de cada objeto, otorgando una flexibilidad representativa sin precedentes. Esta característica es vital en contextos donde la variedad de la información impide una descomposición natural en atributos fijos, como ocurre habitualmente con los mensajes de redes sociales o los registros de actividad web.

Una de las principales ventajas de este tipo de datos es que cada objeto puede contener solo un subconjunto de atributos en relación con otros, adaptándose de manera dinámica a la información disponible. Mientras que las bases de datos SQL requieren un esquema rígido definido antes de la escritura, los sistemas que manejan datos semiestructurados permiten que el esquema evolucione a medida que cambia la comprensión de los datos. Este modelo es la base de las tecnologías NoSQL, las cuales sacrifican parte de la consistencia absoluta y la optimización de consultas complejas en favor de la escalabilidad horizontal y la agilidad en el manejo de diversos formatos.

Dentro del ecosistema de datos, existen dos formatos que dominan la representación semiestructurada:

- › **JSON (*JavaScript Object Notation*)**: es el formato preferido por muchos científicos de datos debido a su simplicidad y ligereza, permitiendo serializar estructuras jerárquicas en texto plano que es legible tanto para humanos como para máquinas. Conceptualmente, un objeto JSON funciona de manera similar a un diccionario de Python, mapeando claves (strings) a valores que pueden ser números, cadenas, booleanos o incluso otros objetos anidados.
- › **XML (*eXtensible Markup Language*)**: similar a JSON en su capacidad jerárquica, se basa en un sistema de etiquetas en par que definen secciones del documento, lo que permite crear lenguajes de descripción específicos para diversos dominios. A diferencia de JSON, los elementos dentro de un documento XML poseen un orden interno intrínseco, y su estructura suele visualizarse como un árbol donde los nodos no hoja contienen etiquetas y los nodos hoja contienen los datos reales.

El auge de estos formatos se encuentra estrechamente vinculado al proceso de datificación ya mencionado, mediante el cual se transforman en datos aspectos de la realidad que anteriormente no eran objeto de registro sistemático. Este tipo de información suele inscribirse dentro de lo que se denomina Big Data, no solo por el volumen que puede alcanzar, sino porque su escasa estructuración tradicional exige el uso de infraestructuras distribuidas y marcos de procesamiento específicos, como Hadoop o Spark. Las tecnologías de Big Data ofrecen la flexibilidad necesaria para operar con estos formatos “desordenados” que harían fallar a las herramientas estadísticas tradicionales.

Sin embargo, aunque los formatos semiestructurados resultan adecuados para la captura y el almacenamiento masivo de información, presentan dificultades para el análisis estadístico profundo. Virtualmente todas las técnicas analíticas, desde simples diagramas de dispersión hasta complejas redes neuronales, requieren que los datos se reduzcan finalmente a una forma tabular (filas y columnas). Por ello, el científico de datos debe dedicar una parte significativa de su tiempo —a menudo entre el 70% y el 80% del proyecto— a tareas de “data wrangling” o “munging”, que consisten en limpiar, normalizar y transformar estos objetos flexibles en registros analíticos estructurados. Este proceso de conversión es costoso y requiere tanto habilidades de ingeniería de software como conocimiento profundo del dominio para no introducir sesgos durante la estructuración.

Para finalizar, el cuadro que sigue permite recuperar de manera sintética las diferencias entre los datos estructurados y los semiestructurados abordadas previamente.

<i>Característica</i>	<i>Datos estructurados</i>	<i>Datos semiestructurados</i>
Almacenamiento	Tablas (<i>filas/columnas</i>)	Objetos, documentos, clave-valor,
Esquema	Fijo y predefinido	Flexible y autodescriptivo
Consultas	SQL (<i>estándar internacional</i>)	Query Languages específicos (<i>ej. NoSQL</i>)
Flexibilidad	Baja (<i>Rígida</i>)	Alta (<i>Evolutiva</i>)
Integridad	Muy alta (<i>transaccional</i>)	Variable (<i>depende del formato</i>)

› **El rol de la preparación de datos**

La preparación de datos es considerada el pilar fundamental de la ciencia de datos, representando el “trabajo pesado” que permite que los métodos estadísticos y de aprendizaje automático sean aplicables. Diversas fuentes coinciden en que los científicos de datos dedican entre el 70% y el 80% (e incluso hasta el 90%) del tiempo total de un proyecto exclusivamente a adquirir, limpiar, integrar y transformar la información.

A diferencia de los conjuntos de datos académicos, los datos provenientes de contextos reales e industriales son inherentemente “sucios”, “desordenados” y “convulsionados”. Esta realidad se rige por el principio de “Garbage In / Garbage Out” (GIGO), según el cual, si los insumos de un proceso computacional son incorrectos, los resultados finales serán necesariamente erróneos. Las patologías o “enfermedades” más comunes de los datos incluyen:

- › **Valores nulos (NULLs):** entradas que faltan debido a fallos técnicos o porque la información no se recolectó para ciertos grupos, lo que puede introducir sesgos si se ignoran.
- › **Entradas duplicadas:** registros repetidos que pueden sobreponderar artificialmente ciertos resultados en los algoritmos.
- › **Valores atípicos (outliers):** datos extremadamente alejados del promedio que pueden

ser errores de medición o eventos extraordinarios (como un ataque de denegación de servicio en un log web) capaces de distorsionar el análisis.

- › **Datos desactualizados o artificiales:** filas que ya no son precisas debido a actualizaciones del sistema o datos insertados para pruebas de software.

Frente a escenario, la limpieza de datos busca mejorar su calidad mediante modificaciones en su forma o contenido. Esto incluye, entre otras tareas, la normalización y estandarización, que permiten convertir los datos a escalas comparables (como el Z-score), lo cual es vital para algoritmos sensibles a la magnitud, como los modelos lineales, SVM o de agrupamiento. Asimismo, comprende la corrección de errores de formato, como capitalizaciones irregulares, espacios en blanco adicionales, delimitadores inconsistentes y formatos de fecha incompatibles. Finalmente, abarca la validación de la integridad de datos mediante “controles de cordura” que aseguren que los datos sean realistas, por ejemplo, verificar que un avión no aterrice antes de despegar.

En paralelo, una parte significativa del trabajo de preparación se vincula con la transformación de datos que no presentan una estructura tabular fija. Gran parte del valor de la ciencia de datos moderna proviene de la datificación de fuentes que antes se descartaban, como archivos de texto, imágenes, audios y logs de servidores. Estos datos a menudo son semiestructurados, como los formatos JSON o XML, o directamente no estructurados, como el lenguaje humano, lo que obliga a “aplanarlos” hasta convertirlos en un registro analítico o tabla base de analítica (analytics base table), donde cada fila represente una instancia y cada columna un atributo numérico o categórico. En el caso específico del texto, este proceso implica tareas como:

- › **Tokenización:** dividir el texto en palabras o unidades básicas.
- › **Eliminación de stopwords:** filtrar palabras comunes sin valor analítico (como “y”, “el”, “de”).
- › **Lematización y stemming:** reducir las palabras a su raíz morfológica (por ejemplo, “corriendo” y “corrió” se reducen a “correr”) para disminuir la dimensionalidad del modelo.

Finalmente, sobre esta base se desarrolla la ingeniería de características (Feature Engineering), considerada un arte basado en la matemática. La creación de características consiste en tomar datos existentes y transformarlos en nuevas variables que capturen mejor la lógica del problema. Esto incluye el binning, entendido como la conversión de variables numéricas en rangos o categorías discretas para reducir el ruido, así como la combinación de variables para representar interacciones complejas.

De manera transversal a todas estas tareas, independientemente del tipo de dato, la preparación de datos es un paso crítico. Los datos del mundo real suelen ser desordenados y requieren limpieza para generar descripciones estadísticamente válidas. En el caso de los datos semiestructurados, a menudo deben ser transformados o “aplanados” en un formato estructurado antes de que se pueda realizar un análisis profundo o aplicar algoritmos de aprendizaje automático.

› Fuentes de datos habituales

En la era actual, la ciencia de datos se fundamenta en la capacidad de extraer valor de una abrumadora cantidad de información recolectada diariamente desde sitios web, dispositivos inteligentes y registros operativos. Este fenómeno, conocido como la ubicuidad de los datos, ha llevado a que empresas de casi todos los sectores busquen explotar la información como un activo estratégico para obtener ventajas competitivas. Para que un científico de datos pueda transformar estos datos en bruto en conocimientos accionables, primero debe dominar las diversas fuentes donde estos residen, las cuales se dividen principalmente en archivos planos y bases de datos estructuradas o no estructuradas, pero también pueden encontrarse otro tipo de archivos.

En este marco, los archivos de texto constituyen la fuente más común de datos brutos, debido a que son legibles por humanos y fáciles de generar mediante scripts. Dentro de este grupo, los *archivos delimitados*, como CSV o TSV, funcionan como el estándar para la representación de datos tabulares; si bien el científico de datos suele trabajar con bibliotecas de alto nivel como Pandas, a nivel del sistema estos archivos se procesan mediante módulos específicos (como `csv` en Python) que permiten manejar complejidades tales como comas incrustadas en campos de texto. Asimismo, cuando se trata de volúmenes muy grandes de información, es habitual recurrir al procesamiento vía *streams* (stdin/stdout), canalizando los datos a través de la entrada y salida estándar para evitar cargarlos completamente en memoria y posibilitar la construcción de tuberías de procesamiento mediante el carácter `|`. En todos los casos, el manejo seguro de archivos resulta un aspecto crítico, siendo una práctica fundamental el uso de estructuras como la declaración *with*, que garantiza el cierre automático de los archivos y previene fugas de memoria o corrupción de datos.

Junto a los formatos de texto plano, muchas organizaciones almacenan información en formatos específicos o binarios que requieren herramientas adicionales para su conversión. Entre ellos, los *archivos de ofimática*, como Excel u otros formatos de Office, si bien son muy comunes, presentan un alto costo computacional de apertura debido a la cantidad de metadatos internos que contienen; por esta razón, en proyectos de ciencia de datos suele recomendarse su conversión temprana a formatos más livianos como CSV. Por otro lado, los *archivos binarios e imágenes* se almacenan como secuencias de bytes puros y pueden adoptar formas rasterizadas, vectoriales o comprimidas, como JPEG, lo que obliga a transformarlos en vectores numéricos o tensores para que los algoritmos de aprendizaje profundo puedan procesarlos. En entornos como Python, además, es frecuente el uso de mecanismos de *serialización* como Pickle, que permiten almacenar y recuperar objetos complejos sin perder su estructura original.

En el ámbito empresarial, el almacenamiento de datos suele organizarse de acuerdo con el propósito para el cual la información es utilizada. Los *sistemas OLTP* (*Online Transaction Processing*) constituyen las bases de datos operativas del día a día—como ventas, inventarios o sistemas CRM—y están optimizados para transacciones rápidas y alta integridad, aunque no para análisis masivos. A partir de estas fuentes, los *data warehouses* o *almacenes de datos* centralizan información proveniente de múltiples sistemas OLTP, facilitando el análisis histórico y la toma de decisiones estratégicas. Complementariamente, los *sistemas OLAP* (*Online Analytical Processing*) permiten explorar los datos mediante cubos con dimensiones predefinidas, posibilitando reportes rápidos, aunque con menor flexibilidad que una consulta directa sobre los datos.

Cuando la información no se ajusta a esquemas tabulares rígidos, se recurre a bases de datos con modelos de almacenamiento alternativos. Entre ellas se encuentran los *almacenes de clave-valor*, comparables a diccionarios de gran escala, como Redis, que resultan ideales para accesos de baja latencia a objetos no estructurados. De manera similar, los *almacenes de documentos*, como MongoDB, permiten guardar datos en formatos flexibles como BSON, facilitando la anidación de campos y su modificación dinámica. Por su parte, los *almacenes de columnas anchas*, como Cassandra o HBase, están diseñados para manejar miles de millones de filas y millones de columnas dispersas, priorizando la escalabilidad.

En paralelo, la web y la nube se han consolidado como fuentes de datos especialmente dinámicas, aunque también la más desordenada. Las *APIs RESTful* representan el mecanismo más robusto y consistente para acceder a información externa, ya que devuelven datos estructurados —generalmente en formato JSON— a partir de solicitudes URL. Cuando estas interfaces no existen, se recurre al *web scraping*, utilizando herramientas como BeautifulSoup para analizar el HTML y extraer información específica, siempre considerando las restricciones establecidas en el archivo robots.txt. A su vez, el *almacenamiento en la nube*, a través de servicios como AWS S3 o Azure, ha desplazado a los servidores locales, ofreciendo una capacidad prácticamente ilimitada a costa de mayores latencias de acceso.

Finalmente, cuando los volúmenes de datos superan la capacidad de una sola computadora, entran en juego las infraestructuras de Big Data. El *Hadoop Distributed File System (HDFS)* permite almacenar archivos dividiéndolos en bloques repartidos por un clúster de servidores, manejando la redundancia automáticamente. Sobre esta infraestructura, frameworks como *Spark* procesan los datos en memoria para aumentar la velocidad, utilizando estructuras como el *RDD (Dataset Distribuido Resiliente)*, que operan bajo un modelo de evaluación “perezosa” (lazy evaluation) hasta que se requiere un resultado final.

En este contexto, las organizaciones modernas suelen adoptar un enfoque híbrido, conectando sus bases de datos tradicionales con clústeres distribuidos, lo que permite al científico de datos consultar ambos entornos mediante SQL como si se tratara de un único sistema.

› **Calidad de los datos: fundamentos e impacto en la Ciencia de Datos**



Énfasis

En la ciencia de datos existe un principio rector ampliamente aceptado que sintetiza la importancia de la calidad de la información: *Garbage In, Garbage Out* (“Basura entra, basura sale”, GIGO, por sus siglas en inglés). Este adagio señala que, independientemente de cuán poderoso sea un algoritmo de aprendizaje automático o cuán sofisticada resulte la infraestructura de cómputo disponible, si los datos de entrada son incorrectos, incompletos o de baja calidad, los resultados obtenidos serán necesariamente erróneos, poco confiables e incluso potencialmente peligrosos para la organización. En este sentido, la calidad del dato constituye la base de todo el universo analítico, ya que determina el grado de validez de las afirmaciones que pueden realizarse sobre la realidad a partir de los análisis.

- **Criterios básicos de calidad de datos**

- › **Compleitud (completeness)**

Uno de los criterios fundamentales para evaluar dicha calidad es la *compleitud*, que se define técnicamente como la situación en la que el valor de un atributo no se conoce o no existe para una instancia determinada. En la práctica profesional, garantizar la completitud es una de las tareas más críticas, ya que alrededor del 80% del tiempo de un proyecto de ciencia de datos se destina a la preparación, limpieza y organización de la información para que sea apta para el análisis.

Los valores faltantes pueden surgir por múltiples causas, que van desde fallos técnicos (como *glitches* en la maquinaria de captura) hasta situaciones en las que la información nunca fue recolectada o no era aplicable a ciertos casos. En entornos industriales, además, es común encontrar que los datos faltantes están mal documentados y solo salen a la luz cuando el científico de datos intenta integrarlos.

La representación de esta “ausencia” de información varía según la herramienta y el sistema. En archivos planos como CSV, la falta de datos puede aparecer como cadenas vacías, “NA”, “NULL”, “unavailable” o “unknown”. A nivel técnico, bibliotecas como Pandas y NumPy emplean valores especiales como NaN (Not a Number) o el valor None de Python para marcar estas celdas, con la particularidad de que los NaN nunca son iguales entre sí, lo que obliga a utilizar funciones específicas, como `isnull()`, para su detección segura. En sistemas más antiguos, que no soportan valores nulos, es habitual encontrar valores centinela arbitrarios, como “-9999”, utilizados para indicar la falta de información.

Si un número significativo de registros carece de información, cualquier análisis posterior resultará inevitablemente sesgado y el peso de las conclusiones se distribuirá de manera impredecible. Este impacto no es homogéneo, sino que se manifiesta de diversas formas. En primer lugar, aparece el sesgo de selección, ya que trabajar solo con registros completos a menudo introduce un sesgo sistemático, ya que los datos faltantes suelen tener características comunes que los excluyeron del conjunto original. Por ejemplo, si en una encuesta de lealtad los clientes insatisfechos omiten su edad, el modelo solo aprenderá del perfil de los clientes satisfechos y no podrá generalizar a toda la población.

En segundo término, se produce una falta de señal en los modelos de aprendizaje supervisado. En estos casos, la presencia de la variable objetivo (target) es indispensable; si la información de retención de un cliente es incompleta, el modelo carece de la “etiqueta” necesaria para aprender, lo que puede conducir al fracaso total del proyecto. Por último, la incompleitud puede generar distorsión estadística, dado que las funciones de agregación (como la media o el máximo) pueden comportarse de forma distinta según la librería; mientras que Pandas suele excluir los NaNs, las funciones nativas de Python podrían propagar el error y arruinar el cálculo.

Frente a este escenario, existen distintos caminos para abordar la falta de datos. En aquellos casos en los que el problema es marginal y no compromete la representatividad del conjunto, puede optarse por eliminar los registros afectados mediante técnicas de *dropping*, borrando filas o columnas con valores nulos. En otras situaciones, se recurre a la

imputación, que consiste en rellenar los valores faltantes a partir de criterios estadísticos como la media, la mediana o el valor más frecuente del atributo; en modelos más complejos, incluso puede imputarse un valor extremo para que el algoritmo aprenda a interpretar la ausencia como una categoría en sí misma.

Una técnica altamente efectiva es la incorporación de variables indicadoras binarias (Is_null), que consisten en crear una nueva columna booleana para señalar si el valor original era nulo o no. Este tipo de variable suele actuar como un proxy informativo sobre el origen del dato, ya que permite capturar patrones subyacentes que el valor observado, por sí solo, podría no revelar. Cuando la variable objetivo es la que falta, puede explorarse el uso de etiquetas proxy, utilizando eventos relacionados que funcionen como sustitutos, por ejemplo, usar las visitas al sitio web como un proxy de la intención de compra cuando no hay datos de transacciones finales. Sin embargo, cuando la falta de datos es estructural, la única solución viable a largo plazo es iniciar proyectos adicionales para recolectar la información necesaria, tratando los datos como un activo estratégico en el que se debe invertir para obtener retornos futuros.

› **Consistencia (consistency)**

Más allá de la completitud, otra dimensión crítica de la calidad es la consistencia, que garantiza que la información mantenga su integridad, formato y significado a medida que fluye a través de diferentes tablas, sistemas o períodos de tiempo dentro de una organización. En el entorno industrial, los conjuntos de datos suelen ser más enrevesados de lo esperado debido a que se generan mediante la combinación de fuentes disparatadas, lo que a menudo revela problemas no documentados que solo el científico de datos identifica durante el análisis. Uno de los desafíos más frecuentes es la falta de estandarización de formatos, un problema común y, a la vez, particularmente tedioso de resolver en los procesos de preparación de datos. Esta falta de uniformidad se manifiesta, por ejemplo, en las discrepancias entre atributos y escalas de medición: un caso clásico es el tamaño del calzado, cuyos valores varían según se utilicen escalas europeas, estadounidenses o del Reino Unido, lo que vuelve imprescindible mapearlos a una representación estándar única antes de aplicar cualquier modelado estadístico. De manera similar, el peso puede registrarse en kilogramos o en gramos, lo que exige su normalización mediante técnicas como el Z-score para garantizar que las variables sean comparables y no introduzcan sesgos en los algoritmos.

Otra fuente habitual de inconsistencias se encuentra en los campos de fecha y hora, que suelen ser los más frecuentemente “mutilados”. Las diferencias pueden aparecer tanto en el formato visual —por ejemplo, “Agosto 1, 2013” frente a “2013-08-01”— como en el nivel de precisión del dato, ya sea que incluya o no horas, minutos o información de zona horaria. A esto se suma que algunos sistemas, como Excel, pueden codificar una misma fecha con valores numéricos distintos según utilicen el sistema de fechas de 1900 o de 1904, lo que obliga a realizar transformaciones cuidadosas para evitar errores de cálculo posteriores. Por su parte, en el caso de los datos planos, también son frecuentes los problemas derivados del uso de delimitadores inconsistentes (comas, tabulaciones o tuberías “|”) y capitalizaciones irregulares que impiden que los algoritmos reconozcan como idénticas dos entradas que solo difieren en el uso de mayúsculas.

Otro problema recurrente en los entornos de datos reales es la existencia de múltiples entradas para una misma entidad, una situación frecuente en bases de datos operativas y en sistemas de procesamiento de transacciones en línea (OLTP), donde la gestión de las actualizaciones puede generar duplicidades o confusión histórica. En muchos contextos industriales, las bases de datos no reemplazan una fila cuando un dato se actualiza, sino que incorporan una nueva con un timestamp más reciente. Así, por ejemplo, en un servicio de suscripción, si un cliente modifica su plan, el sistema puede añadir un nuevo registro en lugar de editar el anterior, lo que obliga al científico de datos a identificar cuál es la entrada vigente y a tratar las restantes como registros históricos.

Esta situación se complejiza aún más cuando no existe un criterio unificado de identificación única. Lograr que cada entidad esté representada por un solo registro constituye, en sí mismo, un problema analítico relevante, ya que dentro de una misma organización distintos sectores pueden identificar a un cliente por atributos diferentes, como el número de teléfono o la dirección de correo electrónico. Esta fragmentación da lugar a silos de datos disjuntos que dificultan la integración de la información y comprometen la coherencia del análisis.

La presencia de registros duplicados no es un problema menor, ya que implica tanto un uso innecesario de recursos computacionales como un riesgo directo sobre la validez de los resultados. Los duplicados sobreponderan artificialmente ciertas observaciones y pueden conducir a conclusiones erróneas, distorsionando el comportamiento de los algoritmos y afectando la interpretación de los modelos.

A estas dificultades se suma la necesidad de comprender el linaje del dato, entendido como el proceso de rastrear la información a lo largo del tiempo para conocer quién la produjo, cómo fue generada y con qué propósito. Resulta fundamental recordar que los datos no constituyen una verdad objetiva, sino que son el resultado de decisiones humanas acerca de qué medir, cómo clasificar y qué registrar, por lo que representan siempre una abstracción parcial y situada de la realidad. Comprender este origen permite evitar análisis que solo reproduzcan artefactos del diseño de captura en lugar de generar conocimiento significativo.

Cualquier modificación en el linaje del dato —como la anonimización o la eliminación de información de identificación personal (PII) para cumplir con regulaciones legales— altera su naturaleza y puede impactar directamente en los modelos construidos a partir de él. Del mismo modo, si se detectan errores en el linaje, como el uso prolongado de un sensor mal calibrado que luego es reemplazado, los modelos previamente entrenados pueden perder validez y requerir un nuevo proceso de ajuste. En este sentido, mantener un registro documentado del linaje permite la revisión por pares y genera solidez y trazabilidad a los resultados obtenidos, generando confianza en los distintos actores interesados (*stakeholders*), asegurando que los resultados de la ciencia de datos sean defendibles desde el punto de vista técnico, organizacional y legal.

› **Validez y exactitud (Validity)**

En estrecha relación con las dimensiones anteriores, la validez y la exactitud constituyen pilares centrales de la calidad de los datos, ya que determinan si la información recolecta-

da representa de manera fiel y útil de la realidad que se pretende estudiar. Mientras que la validez se centra en si los datos cumplen con las reglas lógicas y restricciones del dominio, la exactitud se refiere a la veracidad de los valores registrados en relación con los eventos u objetos reales. Ambas dimensiones resultan inseparables, dado que un dato puede ser formalmente válido y, sin embargo, inexacto, o viceversa.

En la ciencia de datos, todo dato debe entenderse como una abstracción de una entidad del mundo real y, como tal, nunca constituye una representación perfecta, sino una medición atravesada por decisiones de diseño y por los procesos concretos de captura. La validez implica que la información se ajusta a lo que el negocio o el marco científico consideran razonable; por ejemplo, que una variable denominada “edad” no contenga valores de tres dígitos que carecen de sentido biológico en ese contexto. La exactitud, en cambio, garantiza que el dato no ha sido alterado por fallos técnicos, errores humanos o distorsiones introducidas durante su recolección o procesamiento.

Para asegurar la validez, es fundamental entender el linaje del dato y cómo las decisiones humanas, los sesgos y la pragmática de los sistemas de recolección han dado forma a la información. Validar los datos no es un procedimiento meramente técnico, sino una condición necesaria para que el científico de datos pueda avanzar en el análisis con una expectativa razonable de éxito y con la confianza de que los resultados serán representativos de la población estudiada.

En este marco, adquieren especial relevancia los denominados datos “raros” o incongruentes (Weird Data). El término “Weird Data” se refiere a cualquier pieza de información que desafía las suposiciones básicas del mundo real o del problema de negocio. Estos artefactos suelen ser señales de advertencia sobre fallos en la tubería de datos o en la lógica de recolección. Se han documentado casos donde los registros de vuelos muestran que un avión aterrizó antes de despegar, o tiendas que registran ventas de productos con precios negativos, o fábricas que parecen producir mil veces más piezas que sus contrapartes similares sin una explicación lógica.

Las fuentes de estas incongruencias son diversas y pueden incluir desde glitches en sensores y errores de instrumentación hasta ataques que contaminan los registros de tráfico web, o la incorporación de datos artificiales utilizados para pruebas de software que nunca fueron correctamente depurados. El principal riesgo asociado a estos casos reside en asumir que los datos son correctos y continuar el análisis sin cuestionarlos, lo que puede invalidar semanas de trabajo si el problema se detecta en una etapa avanzada. Frente a la presencia de datos atípicos o incoherentes, la recomendación es investigar su origen, contrastar la información con expertos del dominio y, de ser necesario, eliminar estos registros para evitar que introduzcan sesgos en los modelos.

Como instancia final de control, se recurre a los denominados chequeos de sanidad, que consisten en aplicar el sentido común y el conocimiento previo para evaluar si los resultados derivados de los datos son coherentes con verdades conocidas. Este tipo de validaciones permite, por ejemplo, contrastar la cantidad de entidades únicas (como IDs de clientes) con los reportes oficiales de una organización, ya que discrepancias significativas suelen indicar problemas en la identificación de entidades o errores en los procesos de unión entre tablas. Del mismo modo, el análisis de distribuciones mediante histogra-

mas o diagramas de dispersión facilita la detección de valores irreales, rangos excesivos o dispersiones anómalas que afectan las métricas centrales.

En este punto, el juicio experto cumple un rol central, ya que permite discernir si un valor extremo constituye un error o un evento extraordinario legítimo. Por ejemplo, en un análisis de ingresos, el conocimiento del dominio habilita al científico de datos a identificar y filtrar muestras que no resultan representativas, como edades que se encuentran fuera de los rangos lógicos definidos para el estudio. Desde esta perspectiva, el análisis de la validez no se agota en la detección de inconsistencias evidentes, sino que exige considerar las distintas formas en que los datos pueden distorsionarse, las cuales suelen clasificarse en cinco categorías principales:

1. **Comisión:** sustitución deliberada de información verdadera por falsa.
2. **Omisión:** falta de información clave que altera la percepción de la realidad.
3. **Perspectiva:** coexistencia de diferentes visiones de un mismo evento, que generan datos contradictorios, pero “verdaderos” para cada observador.
4. **Sesgo:** prejuicios o creencias personales que distorsionan la visión de la verdad.
5. **Marco de referencia:** el contexto en el que se recolecta el dato puede hacerlo inválido para otro propósito.



Énfasis

En este sentido, la validez y la exactitud no deben entenderse únicamente como requisitos técnicos, sino como un proceso continuo de investigación y adaptación. El científico de datos debe asumir una actitud de vigilancia crítica, documentando cualquier rareza y validando cada supuesto con los actores del dominio, a fin de garantizar que el modelo final represente la verdadera naturaleza de los datos y no las patologías del proceso de captura.



Actividad

Dando por finalizado el desarrollo del contenido del módulo, lo/a invitamos a trabajar con las actividades pertenecientes al módulo. Tenga presente que estaremos disponibles a través del espacio tutorial para que Ud. canalice sus dudas y comentarios.

MÓDULO 2 | GLOSARIO

Abstracción: Representación simplificada de un aspecto de la realidad, construida a partir de decisiones humanas sobre qué medir y cómo hacerlo.

Atributo (Variable): Característica observada de una entidad que se registra en un dataset y se representa como una columna.

Calidad de datos: Grado en que los datos son adecuados para el análisis, evaluado mediante criterios como completitud, consistencia y validez.

Completitud: Criterio de calidad que indica si los valores de un atributo están presentes o ausentes en un dataset.

Consistencia: Criterio de calidad que evalúa la coherencia de los datos en cuanto a formato, significado y valores entre registros o fuentes.

Dato: Medida o registro asociado a una entidad del mundo real, utilizado como insumo para el análisis y la toma de decisiones.

Dataset (Conjunto de datos): Colección organizada de datos que describe un conjunto de entidades mediante atributos comunes, usualmente en forma tabular.

Entidad: Objeto, persona o evento del mundo real que se desea describir mediante datos y que se representa como una fila en un dataset.

Garbage In, Garbage Out (GIGO): Principio que establece que resultados incorrectos son consecuencia directa de datos de entrada de baja calidad.

Linaje del dato (Data Lineage): Información sobre el origen, las transformaciones y el recorrido de los datos a lo largo del tiempo.

Sanity Check (Chequeo de cordura): Validación basada en sentido común y conocimiento del dominio para verificar que los datos sean coherentes con la realidad.

Semiestructurado (Dato): Tipo de dato que no posee una estructura tabular rígida, pero incluye etiquetas o claves que describen su contenido (ej. JSON).

Sesgo: Distorsión sistemática introducida en los datos por decisiones de diseño, recolección o contexto.

Validez: Criterio de calidad que indica si los datos cumplen con reglas lógicas y restricciones propias del dominio.

MÓDULO 2 | ACTIVIDADES



ACTIVIDAD N° 1:

¿Qué es un dato y qué no lo es?

Lea atentamente los siguientes escenarios:

- › Un formulario de inscripción universitaria que solicita edad, carrera y ciudad de residencia.
- › Un comentario libre escrito por un usuario en una red social.
- › El valor “23” almacenado en una base de datos sin contexto adicional.

Para cada caso:

1. Indique si se trata de un dato en el sentido trabajado en el módulo.
2. Explique brevemente qué representa y qué limitaciones o supuestos tiene esa información.



ACTIVIDAD N° 2:

Leyendo un dataset

Se presenta la siguiente tabla simplificada:

id_cliente	edad	ciudad	total_compras
001	34	Córdoba	125000
002	22	Rosario	23000

1. Identifique qué representan las filas y las columnas.
2. Indique qué columna podría presentar problemas de calidad y por qué.
3. Mencione un ejemplo de dato faltante que podría aparecer en este dataset.



ACTIVIDAD N° 3:

Datos faltantes: decidir qué hacer

En un dataset de encuestas, el 30% de los registros no contiene el valor de “*ingreso mensual*”.

1. Mencione dos estrategias posibles para tratar este problema.
2. Indique una ventaja y una desventaja de cada estrategia.
3. Explique por qué eliminar todos los registros puede introducir sesgos.



ACTIVIDAD N° 4: **Sanity checks y sentido común**

En un análisis de vuelos se detecta que algunos aviones “aterrizan” antes de despegar.

1. ¿Por qué este tipo de problema no se detecta solo con estadísticas básicas?
2. ¿Qué herramientas conceptuales del módulo permiten identificar este error?
3. ¿Por qué es importante el conocimiento del dominio en este caso?

MÓDULO 3

Microobjetivos

- › Analizar el proceso ETL como etapa central y recurrente del ciclo de vida de la ciencia de datos, para comprender su relación con la preparación, integración y organización de los datos destinados al análisis.
- › Diferenciar los tipos de datos y sus fuentes habituales de extracción, a fin de valorar sus implicancias en la selección de métodos de obtención y en las decisiones posteriores de análisis.
- › Examinar los principales métodos de extracción de datos según el contexto del problema, para fundamentar criterios básicos de elección entre bases de datos, archivos, APIs y recursos web.
- › Identificar problemas frecuentes en los datos y operaciones elementales de transformación orientadas a su limpieza y estandarización, con el objetivo de asegurar la calidad y confiabilidad del dataset analítico.
- › Relacionar la integración de datos y la conformación de un registro analítico con las prácticas de trazabilidad y documentación del proceso, para fortalecer la reproducibilidad y la preparación para el análisis exploratorio y la modelización.

Contenidos

- **Etapas En Ciencia De Datos I: Extracción, Transformación Y Carga (Etl)**



Fuente: Freepik

- **Introducción al proceso ETL**
- › *El ETL en el marco de CRISP-DM*

Dentro del modelo *CRISP-DM* (*Cross Industry Standard Process for Data Mining*), el proceso ETL se ubica principalmente en la etapa de *preparación de datos*, aunque mantiene una relación estrecha con la etapa de *comprensión de datos*. Este proceso no debe entenderse como una secuencia lineal, sino como un ciclo iterativo de retroalimentación constante. Es frecuente que los primeros resultados del modelado revelen errores en los datos

o pongan de manifiesto la necesidad de atributos no considerados inicialmente, lo que obliga al científico de datos a regresar y reconstruir el conjunto de datos en múltiples ocasiones. En contextos industriales se han documentado casos en los que un mismo dataset es reconstruido hasta diez veces en un período de seis semanas antes de ser validado.

Esta dinámica explica por qué existe un amplio consenso en la industria respecto de que la obtención y preparación de datos consume entre el 70% y el 80% (e incluso hasta el 90%) del tiempo total de un proyecto. Los científicos de datos con mayor experiencia concentran gran parte de sus esfuerzos en esta etapa, conscientes de que acelerar indebidamente el proceso ETL suele comprometer la calidad del modelo y poner en riesgo el éxito del proyecto.

› **El objetivo: La construcción del registro analítico (ABT)**

El fin último del proceso ETL es la conformación de una Analytics Base Table (ABT), también conocida como registro analítico. Esta tabla es el insumo básico de los algoritmos de aprendizaje automático y se caracteriza por:

- › **Estructura matriz:** se organiza como una matriz de $n \times m$, donde las filas representan las instancias u observaciones y las columnas corresponden a los atributos o características.
- › **Abstracción y diseño:** cada fila debe representar una entidad del mundo real (persona, objeto o evento). El éxito depende de identificar las abstracciones correctas; por ejemplo, determinar qué atributos derivados (como el IMC o el porcentaje de bateo) proporcionan un mayor “insight” que los datos crudos originales.
- › **Integración de fuentes dispares:** las corporaciones rara vez mantienen sus datos en un solo lugar. El ETL debe conciliar información proveniente de bases de datos relacionales (SQL), fuentes no estructuradas (redes sociales, audios) y sistemas transaccionales para crear una vista unificada.

› **El principio rector: GIGO (Garbage In, Garbage Out)**

El principio rector GIGO (Garbage In, Garbage Out) resulta central en el análisis de datos y se enfatiza aquí debido a su importancia. Si los insumos son incorrectos o de baja calidad, los resultados obtenidos serán necesariamente erróneos y poco confiables. En este sentido, la *calidad del dato* constituye el cimiento del universo analítico. Cuando no se comprenden las limitaciones o los sesgos presentes durante la etapa de preparación, se corre el riesgo de emitir conclusiones extrañas o inválidas sobre la realidad que se intenta modelar.

Por ello, el científico de datos debe aplicar verificaciones basadas en el sentido común, realizando los denominados *chequeos de sanidad* sobre los resultados. El hecho de que una computadora identifique un patrón no implica que este represente conocimiento real; en muchos casos, puede tratarse simplemente de ruido o de errores sistémicos capturados durante la fase de extracción. Asimismo, durante todo el proceso es necesario mantener una vigilancia extrema para prevenir las denominadas *fugas de datos* (*data leakage*), que ocurren cuando una variable que no estaría disponible en el momento de la decisión real

se incluye de manera inadvertida en los datos históricos de entrenamiento, invalidando la utilidad del modelo.

› Ingeniería analítica y valor estratégico

El ETL transforma el trabajo de un científico de datos de un simple ejercicio de codificación a un proceso de ingeniería analítica. Esto implica tratar los datos como un activo estratégico en el que se debe invertir cuidadosamente.

Mientras que las herramientas de procesamiento tradicionales se optimizan para la consistencia y las transacciones rápidas, el entorno de ETL para la ciencia de datos se enfoca en la exploración y el descubrimiento. En lugar de ser un desarrollo de software rígido, el ETL es una fase de investigación y desarrollo donde el analista utiliza su creatividad para moldear la “arcilla” de los datos brutos hasta convertirla en información valiosa.



El proceso ETL no es un paso previo al análisis, sino que ES parte del análisis mismo. Un dataset bien integrado, limpio y correctamente estructurado permite que la ciencia de datos cumpla su objetivo de producir creencias informadas por evidencia para guiar las acciones del mundo real.

1. Extracción: obtención de datos desde distintas fuentes

La extracción de datos es la fase inicial y crítica del proceso ETL, representando la obtención de la “materia prima” necesaria para fabricar los “ladrillos” del conocimiento. En un mundo saturado de información, el desafío no es la falta de datos, sino saber cómo obtenerlos de fuentes dispares y a menudo desordenadas para construir un registro analítico coherente.

- Tipos de datos a extraer

La naturaleza de la extracción depende enteramente de la estructura original del dato, lo que clasifica la información en tres categorías principales:

Tipo de datos	Organización y estructura	Características principales	Ejemplos / Formatos	Procesamiento
Datos estructurados	Organizados en tablas con esquemas fijos donde cada instancia posee el mismo conjunto de atributos.	Formato más amigable para el análisis. Permiten búsquedas y uniones eficientes.	Hojas de cálculo y bases de datos relacionales.	No requieren técnicas avanzadas específicas para su estructuración, ya que presentan un esquema definido.

Datos no estructurados	Carecen de un orden interno repetible.	Representan la vasta mayoría de la información disponible.	Correos electrónicos, imágenes, audios, videos y PDFs.	Requieren técnicas avanzadas como procesamiento de lenguaje natural (NLP) o visión computacional para extraer atributos numéricos útiles.
Datos semiestructurados	No encajan en tablas rígidas, pero poseen marcadores internos (como etiquetas) que jerarquizan la información.	Constituyen un punto intermedio. Un objeto puede tener un conjunto de atributos diferente al siguiente, lo que otorga gran flexibilidad para capturar variedad de datos.	JSON y XML.	Aprovechan marcadores internos para organizar la información sin requerir un esquema completamente rígido.

- **Fuentes y métodos de extracción habituales**

Las fuentes y métodos de extracción habituales abarcan distintos entornos y tecnologías. En primer lugar, las *bases de datos relacionales* (SQL) constituyen la fuente tradicional por excelencia en contextos corporativos para almacenar datos transaccionales u operativos (OLTP). La extracción se realiza mediante el uso de Structured Query Language (SQL), un estándar internacional que permite definir consultas para filtrar, seleccionar y obtener subconjuntos específicos de información. Entre sus ventajas se destaca la capacidad de manejar volúmenes masivos de datos con alta integridad, así como la posibilidad de realizar operaciones como la unión (JOIN) de múltiples tablas para consolidar información en un registro analítico unificado.

Otra fuente frecuente son los *archivos planos y de ofimática*. Los archivos CSV (Comma-Separated Values) son considerados el “caballo de batalla” de la ciencia de datos, ya que resultan legibles tanto para humanos como para máquinas. No obstante, su aparente simplicidad puede ocultar dificultades, como encabezados adicionales, comillas que contienen comas internas o metadatos incluidos al inicio del archivo. Por su parte, los archivos de Excel, aunque comunes en entornos organizacionales, pueden presentar complejidades derivadas de su formato; por ello, suele preferirse su conversión a CSV o el uso de librerías como pandas para interpretarlos de manera más “inteligente”. En entornos basados en Unix, también es habitual la *manipulación de flujos de datos mediante stdin y stdout*, lo que permite extraer y procesar información de forma secuencial a través de scripts de Python y tuberías (|), creando *pipelines* sin necesidad de cargar el archivo completo en memoria.

Las *fuentes web* constituyen otro ámbito relevante de extracción. Internet representa una fuente dinámica de “datos salvajes” que requiere métodos específicos de captura. Las *APIs* (*Application Programming Interfaces*) ofrecen el mecanismo más robusto y confiable, ya que permiten solicitar datos estructurados directamente a un servicio mediante una URL. Habitualmente, la información se devuelve en formato JSON, que es liviano y fácilmente deserializable en estructuras nativas de Python. Cuando no existe una API disponible, se recurre al *web scraping*, que consiste en automatizar la visita a páginas web para extraer información directamente del código HTML. Herramientas como BeautifulSoup o lxml facilitan la navegación por el árbol del documento y la identificación de etiquetas específicas, aunque esta práctica exige criterios éticos y la revisión del archivo robots.txt para evitar bloqueos o usos indebidos.

Finalmente, cuando los datos superan la capacidad de almacenamiento y procesamiento de una única máquina, se recurre a infraestructuras de *Big Data*. En este contexto, *Hadoop* y su sistema de archivos distribuido (HDFS) permiten almacenar bloques de datos repartidos en un clúster de servidores. El paradigma *MapReduce* aplica una lógica de “divide y vencerás”, en la que una tarea masiva se fragmenta en subprocesos distribuidos (Map) cuyos resultados parciales se combinan posteriormente (Reduce). Asimismo, las bases de datos *NoSQL*—como *MongoDB* (*documentos*), *Cassandra* (*columnas anchas*) o *Redis* (*clave-valor*)— ofrecen esquemas flexibles que posibilitan capturar datos desestructurados o en constante evolución, evitando la rigidez propia de los sistemas relacionales tradicionales.

2. Transformación: limpieza y preparación elemental

La etapa de transformación, comúnmente conocida en la industria como “*data munging*” o “*data wrangling*”, es el proceso de convertir los datos de su formato bruto a uno adecuado para el análisis convencional. Esta fase es considerada el “trabajo pesado” del proceso ETL, donde se identifican y corrigen múltiples problemas antes de que los datos puedan utilizarse de manera confiable.

Los conjuntos de datos industriales suelen ser más enrevesados de lo esperado, presentando problemas de contenido que requieren una labor de “detective” para ser resueltos. Entre ellas se encuentran las *entradas duplicadas*, cuya presencia debe verificarse siempre. Mantener duplicados implica un doble riesgo: por un lado, se consume tiempo computacional innecesario al procesar la misma información repetidas veces; por otro, se introduce un sesgo estadístico, ya que ciertas observaciones quedan sobreponderadas y el algoritmo puede interpretarlas como más relevantes de lo que realmente son. Para resolver este problema, es habitual condensar los registros en una sola entrada o utilizar herramientas como el método *drop_duplicates()* de la librería Pandas.

Distinto es el caso de *múltiples entradas asociadas a una misma entidad*. Aquí no se trata de duplicados exactos, sino de registros diferentes que corresponden, por ejemplo, a un mismo cliente. Esto suele ocurrir porque las bases de datos almacenan nuevas versiones con marcas temporales (*timestamps*) en lugar de reemplazar las anteriores. En estos casos, el científico de datos debe decidir si conservar únicamente el registro más reciente o mantener todos para reconstruir una historia temporal. Situaciones similares se presentan en entornos de manufactura cuando una pieza es reprocesada en la línea de montaje en lugar de descartarse.

Otro problema habitual es la presencia de *valores nulos o faltantes*. La ausencia de datos puede deberse a fallos técnicos (glitches), errores de instrumentación o simplemente a que la información no era aplicable en el momento de la recolección. Existen distintas estrategias para tratarlos: la eliminación (drop) de registros cuando los valores faltantes son aleatorios y no afectan la representatividad; la imputación mediante la media, la mediana o el valor más frecuente; o la creación de indicadores de nulidad (is_null), ya que la ausencia de un dato puede ser informativa por sí misma.

También deben considerarse los *valores atípicos (outliers)*, es decir, observaciones que se alejan significativamente de la tendencia central. Su detección suele realizarse mediante reglas estadísticas, como el análisis de desviaciones estándar o del rango intercuartílico en diagramas de caja (*boxplots*). La decisión sobre su tratamiento depende del contexto: pueden ser errores de medición —como tráfico web generado por bots— o eventos legítimos, pero poco frecuentes como transacciones bancarias inusuales. Según el caso, pueden filtrarse, ajustarse por percentiles o aplicarse técnicas como la winsorización (limitar los valores extremos a un umbral específico).

Además de los problemas de contenido, los problemas de formato constituyen desafíos técnicos que deben resolverse para asegurar que las distintas fuentes de datos sean cohesivas y comparables. Las inconsistencias en texto y espacios son particularmente frecuentes y suelen impedir que las uniones (*joins*) entre tablas se realicen correctamente. Por ejemplo, la presencia de espacios en blanco al inicio o al final de una cadena (como “ABC” frente a “ABC”) es una causa común de fallos en el análisis y debe corregirse mediante métodos como *strip()*. Asimismo, las diferencias en la capitalización (“Python” versus “python”) pueden generar registros aparentemente distintos que en realidad representan la misma categoría, por lo que es necesario normalizar el texto utilizando funciones como *lower()* o *upper()*.

Los campos de fecha y hora constituyen otro foco de dificultades, dado que no existe un estándar universal plenamente adoptado. Es común encontrar formatos dispares o diferencias entre plataformas, como los sistemas de fecha de Excel que comienzan en 1900 o 1904. Del mismo modo, algunos registros incluyen únicamente la fecha mientras que otros incorporan hora, minutos o zona horaria. La transformación debe unificar formato, precisión y zona temporal para permitir cálculos consistentes.

Una vez resueltos los problemas de contenido y de formato, la transformación también implica definir cómo se representarán las variables dentro del modelo analítico. Las variables categóricas (o niveles) representan un conjunto fijo de valores posibles, como el color de un automóvil. Muchos algoritmos, entre ellos la regresión lineal o las máquinas de soporte vectorial (SVM), no pueden procesar texto directamente y requieren que estas variables se conviertan en valores numéricos. La técnica estándar es el *One-Hot Encoding* (también conocido como creación de variables dummy), mediante la cual cada categoría se transforma en una columna binaria independiente: toma el valor 1 si la observación pertenece a esa categoría y 0 en caso contrario.

El *binning o discretización*, por su parte, consiste en transformar variables numéricas continuas en categorías. Por ejemplo, convertir la edad exacta en rangos etarios predefinidos. Esta transformación puede mejorar el rendimiento de los modelos al reducir el ruido

asociado a valores extremos y facilitar la modelización de relaciones no lineales que podrían no capturarse adecuadamente en su forma continua original.



La transformación de los datos no es un paso mecánico, sino un proceso creativo donde el conocimiento del dominio y el sentido común del científico de datos son vitales para estructurar las variables de manera que capturen la verdadera lógica del problema de negocio.

3. Carga e integración: conformación del Dataset Base

La carga e integración representan la fase culminante del proceso ETL, donde los esfuerzos previos de extracción y limpieza convergen para producir el insumo fundamental de cualquier análisis: la *Analytics Base Table* (ABT) o registro analítico. Esta etapa no es simplemente un movimiento de archivos; es el paso donde se le da una estructura matemática coherente a la información para que los algoritmos de aprendizaje automático puedan procesarla.

En cuanto al registro analítico, este adopta la forma de una matriz de datos de dimensión $n \times m$, que funciona como inventario final de la información preparada para el modelado. Esta estructura tabular es el estándar de la disciplina porque permite descomponer entidades complejas del mundo real en atributos procesables. Las filas (n) representan las instancias, casos o unidades de estudio; cada una constituye un feature vector, es decir, una colección ordenada de valores de longitud fija que describe una entidad única, como un cliente específico o una transacción histórica. Las columnas (m) representan los atributos o variables que caracterizan a cada instancia. En esta fase se decide qué atributos incluir con base en el conocimiento del dominio: en un análisis de salud, por ejemplo, pueden incorporarse tanto variables crudas (peso, altura) como variables derivadas (índice de masa corporal), dado que la interacción entre atributos suele resultar más informativa que los datos aislados.

Un aspecto crítico en la conformación de la ABT es la selección de atributos. Eliminar variables redundantes o altamente correlacionadas simplifica los modelos, mejora su interpretabilidad y reduce el riesgo de que los algoritmos identifiquen patrones espurios o irrelevantes.

En relación con la integración de datos, debe considerarse que las organizaciones rara vez concentran su información en un único sistema. Por ello, resulta necesario conciliar y unificar registros provenientes de múltiples bases operativas o fuentes externas. El mecanismo fundamental es la unión (*join*), que empareja registros de diferentes tablas mediante identificadores comunes, como un ID de cliente o un código de producto. En entornos como SQL o Pandas, pueden emplearse distintas estrategias: el *inner join*, que conserva únicamente las coincidencias presentes en ambas fuentes, o el *left join*, que preserva todas las instancias de la tabla principal y completa con valores nulos cuando no existe correspondencia. La elección del tipo de unión es crucial para evitar la pérdida involuntaria de información relevante. Durante este proceso también deben resolverse discrepancias en unidades de medida, escalas o convenciones regionales, por ejemplo, tallas de calzado o monedas, para asegurar que la vista unificada de cada entidad sea estadísticamente válida.

En lo que refiere al destino de la carga, la decisión depende de la escala del proyecto y de la infraestructura disponible. En organizaciones de gran envergadura, el destino habitual es un *Data Warehouse*, repositorio centralizado diseñado específicamente para el análisis y la toma de decisiones, que consolida información proveniente de múltiples sistemas transaccionales (OLTP). Estos almacenes suelen apoyarse en estructuras OLAP (*Online Analytical Processing*), organizadas en cubos de datos con dimensiones predefinidas, por ejemplo, ventas por región y por trimestre, que permiten “rebanar y picar” (*slice and dice*) la información con gran eficiencia para generar reportes ejecutivos. Desde una perspectiva estratégica, contar con un *Data Warehouse* posibilita acceder a años de historial acumulado, facilitando el entrenamiento de modelos de series temporales y el análisis evolutivo de patrones.

En contextos de menor escala o en etapas exploratorias, la carga puede realizarse directamente en el entorno de programación. En Python, la estructura central es el *DataFrame* de Pandas, análogo a una hoja de cálculo altamente flexible que reside en memoria RAM y permite manipulación eficiente, filtrado y aplicación de funciones matemáticas rápidas sobre columnas completas (Series). Los resultados intermedios pueden almacenarse en disco en formatos ligeros como CSV o mediante mecanismos de serialización como Pickle en Python, que permite guardar objetos complejos manteniendo su estado original para usos futuros.



La carga exitosa transforma datos crudos y dispersos en un activo estratégico organizado, permitiendo que el científico de datos pase de la preparación técnica al descubrimiento de hallazgos que resuelvan problemas de negocio reales.

- **Registro del proceso: trazabilidad y reproducibilidad**

Finalmente, el registro del proceso mediante la trazabilidad y la reproducibilidad es lo que permite que la ciencia de datos sea verdaderamente una disciplina científica y no un simple conjunto de conjeturas aisladas. Existe una máxima en la industria: “un proyecto de ciencia de datos que no se puede reproducir no es científico”. Por ello, resulta fundamental mantener un registro exacto de cómo se generó cada número, tabla o gráfico, de modo que cualquier resultado pueda ser explicado y defendido ante un cuestionamiento técnico.

En lo que sigue, se profundizan las dimensiones que hacen posible este registro sistemático del proceso analítico.

En relación con la trazabilidad y el linaje de datos (*Data Lineage*), este se define como el proceso de rastrear la información a lo largo del tiempo, acumulando estadísticas relevantes sobre quién produjo el dato, cómo se transformó y con qué propósito original se recolectó. Este seguimiento es vital para que las organizaciones confíen en sus entornos de datos y aseguren resultados predecibles en sus análisis.

Su importancia estratégica puede comprenderse desde tres dimensiones:

- › En primer lugar, la revisión por pares (peer review): un linaje documentado permite que otros expertos, dentro o fuera de la organización, revisen y validen los procedimientos empleados. De este modo, las decisiones dejan de depender exclusivamente de la intuición individual y se apoyan en procesos verificables.

- › En segundo lugar, el cumplimiento legal y el manejo de Información de Identificación Personal (PII). Legislaciones modernas como el GDPR en la Unión Europea imponen restricciones estrictas sobre el uso de datos personales. Dominar los procesos de anonimización y rastrear el origen de la información no es opcional, sino una competencia profesional obligatoria. Ignorar estas normativas puede derivar en sanciones severas y consecuencias irreversibles para la carrera del especialista.
- › En tercer lugar, la auditoría y defensa de resultados. Un registro exhaustivo permite identificar si una salida inesperada de un modelo responde a una modificación legítima (como un cambio en la limpieza de datos) o a un error en la cadena de procesamiento.

Ahora bien, la trazabilidad por sí sola no garantiza la reproducibilidad. Para que un análisis pueda repetirse meses después con los mismos resultados, es necesario adoptar herramientas y prácticas propias de la ingeniería analítica. En este sentido, la programación literaria, implementada mediante *Jupyter Notebooks*, integra en un mismo documento código ejecutable, visualizaciones y texto explicativo en formato Markdown, lo que facilita la replicabilidad de los experimentos y transparenta el razonamiento analítico.

A esta práctica se suman las *Data Cards* y *Model Cards*, que cumplen una función documental específica. Las primeras describen la procedencia, el tamaño, el formato y los pasos de limpieza aplicados al dataset, así como sus posibles sesgos. Las segundas detallan la arquitectura del modelo, los datos utilizados para el entrenamiento, las métricas de rendimiento y las limitaciones o contextos éticos en los que no debería aplicarse.

De manera complementaria, los comentarios en el código y la documentación sistemática permiten registrar no solo qué se hizo, sino por qué se hizo. Explicar decisiones tomadas ante datos inesperados, dificultades ocultas (*gotchas*) o criterios de selección metodológica genera un capital de conocimiento que trasciende al proyecto puntual. Asimismo, la automatización del análisis (idealmente encapsulada en un único script o notebook ejecutable con un solo comando) evita la pérdida de trazabilidad asociada a ejecuciones manuales dispersas.



Énfasis

La trazabilidad no solo busca el orden técnico, sino la creación de un activo estratégico fiable. Almacenar el código en sistemas de control de versiones como Git, documentar cada transformación del proceso ETL y preservar el linaje de los datos garantiza que el conocimiento no se diluya con el tiempo ni dependa de una sola persona. En definitiva, la calidad del análisis final está directamente vinculada a la integridad del proceso completo: solo un dataset integrado, documentado y reproducible consolida a la ciencia de datos como una disciplina estratégica basada en evidencia.



Actividad

Dando por finalizado el desarrollo del contenido, lo/a invitamos a trabajar con las actividades pertenecientes al módulo. Tenga presente que estaremos disponibles a través del espacio tutorial para que Ud. canalice sus dudas y comentarios.



Evaluación

Luego de haber estudiado los módulos 1, 2 y 3 y tras haber resuelto las actividades, Ud. está en condiciones de resolver la *primera parte de la evaluación integradora*.

MÓDULO 3 | GLOSARIO

Calidad de datos: Grado en que los datos son adecuados para su uso, considerando criterios como completitud, consistencia, validez y ausencia de errores.

Carga de datos: Etapa en la que los datos ya transformados se integran y almacenan en una estructura adecuada para el análisis, como un dataset base o registro analítico.

Datos estructurados: Datos organizados en tablas con un esquema fijo, donde cada registro contiene el mismo conjunto de atributos (por ejemplo, bases de datos relacionales).

Datos semiestructurados: Datos que no siguen un esquema rígido, pero poseen marcas internas que organizan la información, como los formatos JSON o XML.

ETL (Extract, Transform, Load): Proceso que comprende la extracción de datos desde distintas fuentes, su limpieza y preparación, y su posterior carga e integración para el análisis. Es una etapa central y recurrente en la ciencia de datos.

Extracción de datos: Fase del proceso ETL en la que se obtienen datos desde diversas fuentes (bases de datos, archivos, APIs o web), preservando su contenido original para su posterior tratamiento.

GIGO (Garbage In, Garbage Out): Principio que establece que si los datos de entrada son incorrectos o de baja calidad, los resultados obtenidos también lo serán, independientemente de la técnica utilizada.

Integración de datos: Proceso de combinación de datos provenientes de múltiples fuentes mediante identificadores comunes, con el fin de obtener una visión unificada de la entidad analizada.

Registro Analítico (Analytics Base Table – ABT): Tabla estructurada en filas (instancias) y columnas (atributos) que constituye el insumo principal para el análisis exploratorio y la modelización.

Reproducibilidad: Propiedad de un análisis que permite repetir el proceso y obtener los mismos resultados, utilizando los mismos datos, código y condiciones.

Transformación de datos: Conjunto de operaciones destinadas a limpiar, estandarizar y preparar los datos, corrigiendo errores y adecuándolos para su análisis.

Trazabilidad (data lineage): Capacidad de rastrear el origen, las transformaciones y el uso de los datos a lo largo del proceso analítico, permitiendo comprender cómo se obtuvo cada resultado.

Valores atípicos (outliers): Observaciones con valores extremadamente alejados del comportamiento general del conjunto de datos, que pueden representar errores o eventos poco frecuentes.

Valores faltantes (NULL): Ausencia de información en uno o más atributos de un registro, que puede deberse a fallas técnicas, omisiones o datos no aplicables.

MÓDULO 3 | ACTIVIDADES



ACTIVIDAD N° 1:

Reconociendo el proceso ETL en un caso cotidiano

Lea atentamente el siguiente caso:

Una universidad desea analizar la deserción estudiantil. Para ello cuenta con:

- › Una base de datos académica con inscripciones y calificaciones;
- › Planillas Excel con información socioeconómica; y
- › Registros de interacción en la plataforma virtual.

A partir de este escenario, identifique al menos una tarea de extracción, una de transformación y una de carga o integración. Explique brevemente por qué cada una de ellas resulta necesaria dentro del proceso. Recuerde que, antes de realizar cualquier análisis, es indispensable preparar los datos adecuadamente.



ACTIVIDAD N° 2:

Problemas de calidad de datos y principio GIGO

A continuación, se presentan tres situaciones frecuentes en un conjunto de datos:

- › Estudiantes registrados dos veces con el mismo identificador.
- › Edades expresadas en distintos formatos (años completos, rangos, texto).
- › Registros con valores faltantes en variables relevantes.

Indique para cada caso:

1. ¿Qué tipo de problema de datos representa?
2. ¿A qué etapa del proceso ETL corresponde su tratamiento?
3. ¿Por qué podría afectar los resultados si no se corrige (principio GIGO)?



ACTIVIDAD N° 3:

Registro del proceso y reproducibilidad

Explique con sus propias palabras:

1. ¿Qué se entiende por trazabilidad y reproducibilidad en ciencia de datos?
2. Mencione dos prácticas simples que permitirían registrar el proceso de trabajo en un análisis introductorio.
3. Justifique por qué este registro es importante, incluso en análisis pequeños.

MÓDULO 4

Microobjetivos

- › Describir un conjunto de datos mediante medidas básicas de tendencia central y dispersión, para interpretar su comportamiento general y sintetizar información relevante.
- › Explorar distribuciones y relaciones entre variables a través de visualizaciones iniciales, con el objetivo de identificar patrones y tendencias significativas.
- › Identificar la presencia de valores faltantes, a fin de evaluar alternativas básicas para su tratamiento según el contexto del análisis.
- › Detectar valores atípicos utilizando criterios simples, para estimar su posible incidencia en los resultados del análisis.
- › Reconocer inconsistencias o datos incongruentes, con el propósito de determinar la necesidad de revisión o validación previa al análisis.
- › Formular preguntas e hipótesis preliminares a partir de los patrones observados en el análisis exploratorio de datos, para saber orientar etapas posteriores de profundización analítica.

Contenidos

- **Etapas en Ciencia de Datos II: Análisis Exploratorio**



Fuente: Freepik


Luego de preparar los datos en el módulo anterior, es momento de preguntarse qué historia cuentan antes de avanzar hacia el modelado.

El análisis exploratorio de datos (EDA) representa la etapa creativa y de descubrimiento en la ciencia de datos, donde el analista “interroga” al conjunto de datos para entender su estructura interna antes de aplicar modelos complejos. A diferencia de un enfoque confirmatorio, que busca probar una teoría preexistente, el EDA permite que los datos sugieran patrones y guíen la formulación de preguntas.

› Descriptores básicos y visualización inicial

Tras preparar los datos, el siguiente paso consiste en detenerse a observar qué nos muestran antes de avanzar hacia el modelado. En esta etapa, el análisis exploratorio se apoya en la estadística descriptiva para ofrecer una primera comprensión del dataset. A continuación, trabajaremos con algunas métricas y herramientas que se profundizarán en otras materias de la licenciatura, pero que aquí cumplen un papel clave para comenzar a interpretar la información con fundamento.

En esta línea, las medidas de tendencia central ayudan a resumir un conjunto de datos en un solo valor que refleje su comportamiento típico. La media () representa el promedio aritmético de todos los valores y ofrece una visión general del rendimiento; sin embargo, su sensibilidad a los valores atípicos (outliers) puede desplazarla del “pico” real de la distribución. La mediana, al ubicarse en el centro de los datos ordenados, divide el dataset en dos partes iguales y constituye una medida robusta, especialmente útil en distribuciones sesgadas. La moda identifica el valor o categoría que ocurre con mayor frecuencia; en distribuciones bimodales, pueden existir dos modas, lo que sugiere la presencia de grupos diferenciados dentro de los datos. Por último, los cuantiles y percentiles dividen la información en subgrupos proporcionales, y el resumen de cinco números mínimo, Q1, mediana, Q3 y máximo permite describir de manera rápida la forma general de la distribución.



Fuente: Elaboración propia mediante IAG.

Para profundizar la comprensión del dataset, también resulta necesario analizar qué tan dispersos o agrupados se encuentran los valores respecto al centro. En este sentido, el rango expresa la diferencia simple entre el valor máximo y el mínimo, proporcionando una primera medida de amplitud.

Por su parte, la varianza () mide la desviación cuadrática promedio respecto a la media, mientras que la desviación estándar (), como raíz cuadrada de la varianza, resulta más intuitiva ya que conserva las mismas unidades que los datos originales. Una desviación alta en relación con la media indica gran dispersión o la presencia de valores inusuales.

Asimismo, el rango intercuartílico (IQR), calculado como la diferencia entre el percentil 75 (Q3) y el 25 (Q1), permite evaluar la dispersión central y constituye una herramienta clave para detectar outliers en los gráficos de caja.

Más allá de la tendencia central y la dispersión, el análisis exploratorio de datos busca identificar si la distribución se aproxima a una distribución normal o gaussiana. El skewness (sesgo) mide la asimetría: un valor negativo indica una “cola” más larga a la izquierda, mientras que un valor positivo indica una cola hacia la derecha. Por otro lado, la kurtosis (curtosis) indica si la distribución presenta un pico pronunciado o una forma más plana. Estos indicadores son útiles para determinar si es necesario aplicar transformaciones, como logaritmos, antes de utilizar algoritmos sensibles a la forma de la distribución.




Énfasis

Para facilitar estos análisis, herramientas como Pandas permiten generar de manera automática resúmenes estadísticos con `.describe()`, incluyendo conteo, media, desviación estándar, mínimos, máximos y cuartiles. Complementariamente, SciPy (`scipy.stats`) ofrece un amplio repertorio de funciones estadísticas y distribuciones, tanto continuas como discretas, que permiten modelar comportamientos más complejos dentro del dataset.

► Visualización inicial: el arte de ver patrones

Finalmente, la visualización constituye un componente indispensable del análisis exploratorio. El ojo humano detecta patrones y anomalías que las estadísticas crudas no revelan, como lo demuestra el famoso Cuarteto de Anscombe, donde datasets con estadísticas idénticas presentan patrones visuales totalmente distintos.



El Cuarteto de Anscombe (Anscombe's quartet) es un conjunto de cuatro conjuntos de datos creados en 1973 por el estadístico británico Francis Anscombe. El ejemplo ilustra cómo datos con idénticos estadísticos descriptivos pueden tener distribuciones gráficas muy distintas. Fuente: Wikipedia.

Por ejemplo, los histogramas permiten observar la forma general de los datos y detectar picos o brechas; es importante seleccionar cuidadosamente el número de bins, ya que pocos pueden ocultar patrones y demasiados generar ruido. Los gráficos de barras son ideales para comparar cantidades discretas, prestando atención a que el eje Y comience en cero para no exagerar diferencias mínimas. Los diagramas de dispersión (scatterplots) muestran la relación entre dos variables emparejadas y permiten identificar correlaciones positivas, negativas o nulas.

De manera complementaria, los boxplots facilitan visualizar la dispersión y detectar outliers mediante los “bigotes” del gráfico. Por último, cuando se trata de datos multidimensionales, las matrices de dispersión y los heatmaps permiten examinar de manera simultánea las correlaciones entre todas las variables, ofreciendo una visión integral del comportamiento del dataset.

› **Identificación de patrones, valores faltantes y atípicos**

Antes de profundizar en modelos o predicciones, es fundamental explorar los datos para reconocer patrones, detectar valores faltantes y observar posibles anomalías. Esta etapa de inspección permite comprender mejor la estructura del dataset y anticipar problemas que podrían afectar los análisis posteriores.

Los *valores faltantes* (*Missing Values* y *NULLs*) ocurren cuando un atributo no tiene un dato disponible para una instancia específica. Esta situación puede deberse a diferentes causas, como mal funcionamiento de instrumentos de medición, falta de aplicabilidad del atributo (por ejemplo, información de cónyuge en personas solteras) o simplemente porque la información nunca fue recolectada. En Python, estos casos se representan mediante NaN (Not a Number) de NumPy o None. Es importante tener en cuenta que dos NaN nunca son iguales entre sí, por lo que la función `.isnull()` constituye la forma confiable de identificarlos. Para tratarlos, se pueden eliminar las filas con valores nulos cuando estos son pocos y aleatorios, o se pueden imputar rellenando los huecos con la media, la mediana o algún valor estadístico relevante. Otra alternativa consiste en crear un indicador binario (`is_null`) que marque si el dato original faltaba, lo cual permite descubrir patrones sobre por qué ciertos datos no se recolectaron, como ocurre en algunos grupos demográficos que omiten información sensible.

Por otra parte, los *valores atípicos* (*outliers*) corresponden a registros que se apartan significativamente del comportamiento general de la muestra debido a valores inusualmente altos o bajos. Su presencia puede inflar la varianza y distorsionar medidas de tendencia central como la media, desplazándola lejos del “hump” o del verdadero “pico” de la distribución. Asimismo, estos casos extremos pueden inducir a los algoritmos de aprendizaje automático a enfocarse en situaciones marginales en lugar de capturar patrones estructurales del conjunto de datos. A nivel univariante, los diagramas de caja permiten identificar visualmente los puntos fuera de los “bigotes”, que suelen situarse a 1,5 veces

el rango intercuartílico (IQR). Además, es posible detectar valores atípicos mediante la regla de la desviación estándar, considerando como potenciales outliers aquellos registros que se alejan de la media en más de dos o tres desviaciones estándar. Este criterio se basa en el comportamiento esperado de muchas distribuciones estadísticas, donde la mayor parte de los datos se concentra alrededor del promedio. En este contexto, la desigualdad de Chebyshev proporciona un marco teórico más general, ya que establece que, independientemente de la forma de la distribución, la proporción de datos que se encuentra a más de k desviaciones estándar de la media es como máximo $1/k^2$. En consecuencia, cuando un valor se sitúa a siete o más desviaciones estándar, la probabilidad de que pertenezca al comportamiento habitual de la muestra es extremadamente baja, lo que lo convierte en un candidato muy fuerte a ser considerado un outlier.

No obstante, algunos valores atípicos solo se evidencian al analizar simultáneamente varias variables. En este sentido, técnicas multivariantes como el Análisis de Componentes Principales (PCA) permiten proyectar los datos en espacios de menor dimensión, donde las observaciones que no se ajustan a la estructura principal se vuelven más visibles. Del mismo modo, algoritmos de agrupamiento como DBScan basados en densidad pueden identificar puntos aislados en regiones poco pobladas, mientras que métodos como Isolation Forest evalúan qué tan fácilmente puede aislarse un dato del resto; cuanto menos esfuerzo requiera su separación, mayor será la probabilidad de que se trate de un outlier.

Finalmente, existen datos que no solo son extremos, sino directamente incongruentes con la realidad. Estos “*datos raros*” incluyen registros que violan supuestos básicos, como vuelos que aterrizan antes de despegar, precios negativos en comercios o producciones físicamente imposibles. Lejos de ignorarlos automáticamente, resulta fundamental investigar su origen junto con expertos del dominio. En ciertos casos se tratará de fallos técnicos o errores de carga (*glitches*), pero en otros pueden representar descubrimientos significativos, como ocurrió históricamente cuando mediciones consideradas “demasiado bajas” terminaron evidenciando el agujero en la capa de ozono.

› *Formulación de hipótesis a partir del EDA*



Énfasis

La formulación de hipótesis a partir del análisis exploratorio de datos marca el pasaje desde la observación descriptiva hacia la construcción de interpretaciones fundamentadas. En esta instancia, los datos dejan de ser un conjunto de registros y comienzan a convertirse en evidencia que orienta decisiones. A diferencia de un enfoque estrictamente confirmatorio, centrado en validar una teoría previa, el EDA habilita un recorrido inverso: permite que los propios datos sugieran preguntas, tensiones y posibles explicaciones mediante un proceso de descubrimiento progresivo.

Desde esta perspectiva, el desarrollo de la intuición ocupa un lugar central. El científico de datos no se limita a aplicar técnicas, sino que aprende a “leer” el comportamiento del dataset. Tal como un escultor elimina el material sobrante para revelar la forma latente, el analista identifica y controla el ruido (valores atípicos extremos, errores de captura o inconsistencias) para que emerjan las estructuras significativas. Esta práctica repetida construye un criterio que difícilmente pueda adquirirse únicamente a través de fórmulas.

En ese mismo sentido, el contacto visual con los datos fortalece lo que podría llamarse un sentido intuitivo de los patrones. Las representaciones gráficas permiten advertir concentraciones, asimetrías, rupturas o regularidades que en una tabla numérica pasarían inadvertidas. Dado que el cerebro humano procesa estímulos visuales con mayor eficacia que largas secuencias de cifras, la visualización se convierte en un instrumento cognitivo, no meramente estético.

Ahora bien, esta ampliación de la intuición también implica superar los límites naturales de nuestra capacidad analítica. Mientras que de forma manual resulta difícil considerar simultáneamente más de dos o tres variables, las herramientas computacionales posibilitan explorar interacciones entre decenas o incluso miles de atributos. El EDA asistido por software no reemplaza el juicio humano, pero lo expande, revelando dependencias complejas que de otro modo permanecerían ocultas.

A medida que el análisis avanza, también se hacen visibles posibles patologías en los datos. Inconsistencias sutiles, distribuciones inesperadas o relaciones improbables pueden señalar problemas de diseño en la captura de información. Detectar estas anomalías en esta etapa evita que el modelo posterior aprenda artefactos del sistema de registro en lugar de patrones genuinos del fenómeno estudiado.

‣ *De la exploración al modelo: la visualización como motor de hipótesis*

Las gráficas producidas durante el EDA no cumplen únicamente una función ilustrativa. Por el contrario, actúan como disparadores conceptuales que orientan la formulación de hipótesis concretas sobre el comportamiento del mundo real. Un diagrama de dispersión (*scatterplots*), por ejemplo, puede sugerir la existencia de una relación lineal entre dos variables o evidenciar o si presentan dependencias más complejas, motivando hipótesis de correlación o influencia. En ambos casos, la visualización antecede a la formalización estadística.

De manera similar, un histograma con dos picos claramente diferenciados invita a considerar que la población analizada no es homogénea. Esa simple observación puede conducir a hipótesis sobre la existencia de subgrupos naturales con comportamientos distintos, lo que a su vez abre la puerta a estrategias de segmentación más refinadas.

Cuando emergen agrupaciones espontáneas en el espacio de variables, la intuición visual puede transformarse en una tarea formal de clustering. Lo que comienza como una percepción gráfica de proximidad termina traducéndose en perfiles de usuario, tipologías de comportamiento o estrategias diferenciadas de intervención.

Incluso en etapas tempranas, la visualización permite evaluar si existe suficiente señal en los datos como para justificar un proyecto de aprendizaje automático de mayor escala. Si las relaciones aparentes son débiles o inconsistentes, el analista puede reconsiderar la viabilidad del enfoque antes de invertir recursos significativos.

‣ *Validación de suposiciones y chequeos de coherencia (sanity checks)*

Junto con la creatividad exploratoria, el EDA exige una actitud crítica permanente. Mantener una cierta “paranoia saludable” protege al análisis de conclusiones apresuradas derivadas de errores técnicos o supuestos mal verificados.

En este marco, los llamados chequeos de cordura o sanity checks consisten en contrastar los resultados obtenidos con hechos previamente conocidos. Por ejemplo, si el conteo de identificadores únicos de clientes no coincide con los registros oficiales de la organización, la discrepancia difícilmente pueda atribuirse a un descubrimiento novedoso; lo más probable es que exista un problema en la identificación de entidades o en la consolidación de bases. Asimismo, cuando los resultados contradicen principios físicos o lógicos como temperaturas imposibles, fechas inconsistentes o precios negativos, la sospecha debe dirigirse primero hacia la calidad del dato. Muchas veces, estas incongruencias se explican por convenciones internas, códigos especiales o documentación incompleta que requieren revisión.

Este proceso crítico puede conducir, además, a un remarcado del problema inicial. No es extraño que, al comprender con mayor profundidad las limitaciones y posibilidades del dataset, la formulación original del problema se modifique. Este ajuste constituye una señal de madurez analítica, ya que el problema se redefine en función de lo que realmente puede investigarse con la información disponible.



Énfasis

En definitiva, el análisis exploratorio no es un trámite previo al modelado, sino un espacio donde se construye comprensión estratégica. A través de la iteración constante entre visualización, interpretación y reformulación de hipótesis, se genera *conocimiento accionable*. Este proceso permite a las organizaciones anticiparse a tendencias, detectar riesgos y diseñar intervenciones informadas. Un EDA riguroso garantiza que los modelos posteriores aprendan patrones estructurales y no simplemente el ruido particular de una muestra. De este modo, la fase exploratoria se convierte en el fundamento epistemológico y operativo de todo el proyecto analítico.



Actividad

Dando por finalizado el desarrollo del contenido, lo/a invitamos a trabajar con la actividad perteneciente al módulo. Tenga presente que estaremos disponibles a través del espacio tutorial para que Ud. canalice sus dudas y comentarios.

MÓDULO 4 | GLOSARIO

Asimetría (skewness): Medida que indica si una distribución presenta mayor concentración de valores hacia la izquierda o hacia la derecha respecto de la media.

Boxplot (diagrama de caja): Gráfico que resume la distribución de un conjunto de datos mostrando mediana, cuartiles y posibles valores atípicos.

Curtosis (kurtosis): Medida que describe el grado de concentración de los valores en torno a la media y la presencia de colas más o menos pronunciadas.

Cuartiles: Valores que dividen un conjunto de datos ordenados en cuatro partes iguales (Q1, Q2 o mediana y Q3).

Dataset: Conjunto estructurado de datos organizado en filas y columnas para su análisis.

Desviación estándar: Medida de dispersión que indica cuánto se alejan, en promedio, los valores respecto a la media.

EDA (Análisis Exploratorio de Datos): Etapa del proceso de ciencia de datos orientada a describir, visualizar y comprender un conjunto de datos antes de aplicar modelos predictivos.

Histograma: Gráfico que representa la distribución de una variable numérica agrupando los valores en intervalos.

IQR (rango intercuartílico): Diferencia entre el tercer y el primer cuartil ($Q_3 - Q_1$), utilizada para medir dispersión y detectar valores atípicos.

Media: Promedio aritmético de un conjunto de valores numéricos.

Mediana: Valor central de un conjunto de datos ordenados que divide la muestra en dos partes iguales.

Outlier (valor atípico): Dato que se aleja significativamente del resto de los valores del conjunto.

Rango: Diferencia entre el valor máximo y el valor mínimo de un conjunto de datos.

Sanity check: Chequeo básico de coherencia realizado para verificar que los datos o resultados no contradigan supuestos conocidos.

Valores faltantes (missing values): Datos ausentes o no registrados en una variable determinada.

MÓDULO 4 | ACTIVIDADES



ACTIVIDAD N° 1:

Detección de inconsistencias y sanity checks

En un análisis exploratorio de datos académicos se observan los siguientes casos:

- › Existen estudiantes con edad igual a 3 años.
- › Se registran notas finales de 11 y 12 en un sistema cuya escala oficial es de 1 a 10.
- › El total de estudiantes informados por el sistema es 950, pero el conteo de IDs únicos arroja 1.020.
- › La variable “promedio_general” presenta varios valores faltantes.

A partir de esta información:

1. Clasifique cada situación (*dato incongruente, valor faltante, problema de identificación, posible error de carga*).
2. Explique por qué estos casos deben revisarse antes de cualquier modelización.
3. Describa qué preguntas debería realizar el/la científico/a de datos al equipo institucional.
4. Escriba una reflexión sobre los riesgos y posibles consecuencias de ignorar estos problemas.

MÓDULO 5

Microobjetivos

- › Interpretar el concepto de modelo en ciencia de datos, para comprender su función dentro del proceso general de análisis y su papel en la construcción de predicciones.
- › Describir el aprendizaje supervisado como enfoque de modelización basado en datos etiquetados, con el objetivo de reconocer su aplicación en problemas predictivos concretos.
- › Diferenciar problemas de clasificación y regresión, a fin de identificar la naturaleza de la variable objetivo y seleccionar el tipo de modelo adecuado en cada caso.
- › Examinar el concepto de generalización en modelos predictivos, para valorar su importancia en la evaluación de la utilidad y el desempeño fuera de los datos de entrenamiento.
- › Distinguir sobreajuste y subajuste a nivel conceptual, con el propósito de reconocer sus implicancias en la capacidad predictiva de un modelo.
- › Interpretar matrices de confusión y métricas básicas de evaluación, para fundamentar la validación de modelos mediante el uso de datos separados y obtener resultados confiables.

Contenidos

- **Etapas En Ciencia De Datos III: Modelización, Predicción Y Clasificación**



Fuente: Freepik

El Módulo 5 se centra en la etapa en la que los datos previamente procesados se emplean para construir representaciones matemáticas capaces de inferir conocimiento y anticipar eventos futuros. En esta instancia, el Aprendizaje Automático (Machine Learning) se convierte en el componente central del proceso, dando continuidad al trabajo realizado en la fase de preparación de datos.

› *Ideas generales sobre modelización*

La modelización constituye el núcleo de la ciencia de datos, ya que actúa como puente entre los datos en bruto y la toma de decisiones fundamentada. En esta sección se pro-

fundiza en los conceptos centrales de la modelización y en el enfoque del aprendizaje supervisado, que es uno de los marcos más utilizados en el análisis predictivo.

› ¿Qué es un modelo en Ciencia de Datos?



Énfasis

En términos generales, un modelo es una representación simplificada de la realidad creada con un propósito específico. Esta simplificación se apoya en determinadas suposiciones acerca de qué información resulta relevante y cuál puede omitirse, abstrayendo así detalles que no resultan necesarios para abordar el problema planteado. En nuestra disciplina, un modelo resume un conjunto de datos a través de una estructura matemática o probabilística que ilustra la relación entre variables. Su finalidad, puede ser tanto descriptiva para explicar patrones existentes como para realizar predicciones sobre eventos no observados.

La creación de un modelo a partir de los datos se conoce técnicamente como *inducción de modelos*. A diferencia de la deducción, que parte de principios generales para derivar conclusiones particulares, la inducción recorre el camino inverso: toma casos específicos (los datos) para generalizar reglas o leyes estadísticas. El procedimiento algorítmico que lleva adelante esta tarea se denomina algoritmo de inducción o aprendiz (learner). Este algoritmo extrae dos componentes fundamentales, por un lado, la estructura del modelo como puede ser, la forma de un árbol de decisión y, por otra parte, sus parámetros numéricos, como los coeficientes en una regresión.

Dentro de este marco, el *aprendizaje supervisado* constituye el enfoque predominante para la modelización predictiva. Se basa en el paradigma de aprender una función que mapee vectores de entrada a sus valores objetivo conocidos. Para ello, el algoritmo necesita datos etiquetados, es decir, ejemplos en los que la variable de interés, la etiqueta o target, ya está disponible. Se denomina supervisado porque el propio conjunto de datos actúa como guía, proporcionando retroalimentación constante: el modelo compara su predicción con el valor real y ajusta sus parámetros para reducir el error. Dado que el espacio de funciones posibles es prácticamente infinito, cada algoritmo incorpora un sesgo de aprendizaje, entendido como una preferencia por determinados tipos de soluciones que orienta la búsqueda.

El proceso de entrenamiento implica resolver un problema de optimización. El objetivo es encontrar los parámetros que permitan al modelo ajustarse a los datos de la mejor manera posible. Para evaluar el desempeño se definen funciones matemáticas específicas. Una función de pérdida, como el error cuadrático, mide la “irritación” o el costo asociado a cometer errores de predicción y el entrenamiento consiste en minimizar ese valor. Otra perspectiva habitual es la de máxima verosimilitud, que busca maximizar la probabilidad de que los datos observados hayan sido generados por el modelo bajo ciertos parámetros. Esta búsqueda se realiza dentro de una familia de modelos denominada espacio de hipótesis, como ocurre con el conjunto de todas las rectas posibles en una regresión lineal.



Énfasis

Uno de los desafíos centrales de la modelización es que el modelo no solo funcione bien con los datos utilizados para entrenarlo, sino que mantenga un desempeño similar cuando se enfrenta a datos nuevos. A esta capacidad se la denomina generalización. En otras palabras, un modelo generaliza adecuadamente cuando logra capturar patrones reales del fenómeno y no simplemente particularidades del conjunto de entrenamiento.

Un modelo con buena generalización presenta un rendimiento similar en los datos de entrenamiento, denominado error in sample, y en datos nuevos o de prueba, denominado error out of sample. No se trata solo de obtener buenos resultados iniciales, sino de evitar discrepancias cuando el modelo se enfrenta a situaciones reales.

Cuando el modelo se adapta de manera excesiva a los datos de entrenamiento se produce el fenómeno de sobreajuste, conocido como overfitting. En este caso, el algoritmo termina capturando el ruido y las correlaciones espurias, memorizando particularidades del conjunto de entrenamiento gracias a un número excesivo de parámetros. El síntoma característico es un rendimiento excelente en los datos de entrenamiento acompañado de un desempeño deficiente en los datos de prueba. Entre las causas más frecuentes se encuentran el uso de modelos demasiado complejos para conjuntos de datos pequeños o la incorporación de demasiadas variables en relación con el número de observaciones. Para mitigar este problema se emplean estrategias como la división entre entrenamiento y prueba, la validación cruzada, la regularización, que penaliza coeficientes grandes, la poda de árboles y técnicas de ensamble.

En el extremo opuesto se encuentra el subajuste, conocido como underfitting, que ocurre cuando el modelo es demasiado simple para captar la estructura básica de los datos. En este escenario, el desempeño es pobre tanto en entrenamiento como en prueba, ya que el modelo no dispone de la flexibilidad necesaria para representar adecuadamente el fenómeno. Para abordarlo puede ser necesario incorporar nuevas características o utilizar algoritmos con mayor capacidad de representación.

Finalmente, el denominado compromiso entre sesgo y varianza, o bias variance trade off, ofrece una formulación técnica del equilibrio entre simplicidad y complejidad. El sesgo es el error que surge de suposiciones excesivamente simplificadoras; los modelos simples suelen presentar alto sesgo porque no capturan la complejidad del problema. La varianza, en cambio, es el error asociado a una sensibilidad excesiva frente a las fluctuaciones del conjunto de entrenamiento; los modelos muy complejos presentan alta varianza y tienden a producir predicciones inestables ante datos nuevos. El desafío consiste en encontrar un punto de equilibrio donde la combinación de ambos errores sea mínima. En términos generales, aumentar la complejidad reduce el sesgo, pero incrementa la varianza. Una estrategia habitual para disminuir la varianza sin aumentar el sesgo consiste en disponer de más datos de entrenamiento, lo que favorece el aprendizaje de patrones más generales en lugar de adaptaciones a ruidos locales.

› **Predicción y clasificación**

El modelado predictivo constituye una de las tareas centrales de la ciencia de datos y consiste en construir una regla o función capaz de estimar el valor de una variable objetivo, denominada target, cuando ese valor es desconocido para una instancia determinada. Aunque en el lenguaje cotidiano la palabra predicción suele asociarse con el futuro, en este campo se utiliza en un sentido más amplio: implica estimar cualquier valor no observado, ya sea futuro, presente o incluso pasado.

Dentro del modelado predictivo pueden distinguirse dos grandes enfoques según la naturaleza de la variable objetivo: la clasificación y la regresión.

La clasificación se emplea cuando la variable objetivo es categórica o discreta. En este caso, el propósito es asignar cada instancia a una de un conjunto finito de clases mutuamente excluyentes. Desde una perspectiva aplicada, puede entenderse como una forma de segmentación supervisada, ya que permite dividir la población en subgrupos que difieren respecto de una cualidad de interés. Un clasificador funciona como una regla que toma un conjunto de características de entrada y devuelve una etiqueta específica.

Existen distintos tipos de clasificación. Se habla de clasificación binaria cuando solo hay dos resultados posibles, como aprobar o no aprobar, aceptar o rechazar, éxito o fallo. En cambio, la clasificación es multiclase cuando la variable objetivo puede adoptar más de dos categorías, por ejemplo, seleccionar entre distintos planes de servicio.

En muchos contextos no basta con asignar una etiqueta; también resulta relevante estimar la probabilidad asociada a cada clase. Esta estimación probabilística, conocida como *scoring*, permite tomar decisiones más informadas, especialmente cuando intervienen costos y beneficios diferenciados. Por ejemplo, puede priorizarse la intervención sobre aquellos casos cuya probabilidad de abandono o incumplimiento sea más alta.

Algunos ejemplos clásicos de clasificación incluyen la detección de spam, donde los mensajes se categorizan como deseados o no deseados a partir de ciertas características textuales; la evaluación de riesgo crediticio, que estima la probabilidad de incumplimiento de pago según atributos financieros e históricos; y el diagnóstico médico, donde se determina la presencia o ausencia de una enfermedad a partir de datos clínicos o imágenes.

Por su parte, la regresión se emplea cuando el objetivo es estimar un valor numérico real, continuo o cuantitativo. A diferencia de la clasificación, que busca determinar si algo ocurrirá o a qué categoría pertenece una instancia, la regresión intenta estimar *cuánto* ocurrirá. Su propósito es modelar la relación entre variables independientes, también llamadas predictores, y una respuesta numérica, con el fin de cuantificar los cambios esperados en esa variable cuando se modifican los factores explicativos. Por ejemplo, permite analizar cuánto varía el tiempo de permanencia en un sitio web al incrementarse el número de amigos de un usuario.

Entre las técnicas más utilizadas se encuentra la regresión lineal, tanto en su versión simple como múltiple, considerada el método estándar para estimar valores numéricos cuando se asume una relación lineal entre la variable dependiente y las variables independientes.

Algunas aplicaciones frecuentes incluyen la estimación de precios de mercado, como el valor de una vivienda según su tamaño, número de habitaciones y ubicación, o el precio de un automóvil en función de su antigüedad y kilometraje. También se utiliza en el análisis de series temporales, por ejemplo, para proyectar el valor futuro de una variable a partir de mediciones recientes, como la evolución de indicadores ambientales. Asimismo, permite calcular tendencias y rentabilidad, como la ganancia esperada de un negocio, el volumen de ventas, la demanda de un producto o los ingresos potenciales asociados a un nuevo cliente.



Énfasis

La distinción fundamental entre regresión y clasificación radica en la naturaleza del objetivo: la regresión trabaja con valores numéricos, mientras que la clasificación se ocupa de categorías. No obstante, desde el punto de vista estructural, ambas comparten la misma lógica: construir un modelo capaz de estimar el valor faltante de un atributo a partir de un conjunto de variables de entrada.

› Evaluación básica de resultados

La evaluación de modelos es la etapa crítica que determina si una abstracción matemática tiene utilidad real o si es simplemente un artefacto estadístico sin valor práctico. El objetivo fundamental no es obtener un rendimiento perfecto en los datos que ya conocemos, sino asegurar que el modelo sea capaz de generalizar, es decir, realizar predicciones precisas sobre datos nuevos que nunca ha visto. Como ya hemos visto error común en la ciencia de datos es confundir un buen rendimiento en el entrenamiento con un modelo exitoso, esto puede ser causado por:

Sin embargo, el verdadero criterio de éxito es su capacidad de mantener resultados consistentes cuando se aplica a datos nuevos. De lo contrario, pueden aparecer problemas ya trabajados anteriormente, como el sobreajuste, cuando el modelo se adapta en exceso a los datos de entrenamiento y termina “memorizando” el ruido y las anomalías de los datos de entrenamiento en lugar del patrón real, o el subajuste, cuando su simplicidad le impide capturar los patrones fundamentales. Por ello, la evaluación no se orienta a medir cuánto “aprendió” el modelo sobre el conjunto conocido, sino a estimar qué tan confiables serán sus predicciones en escenarios reales.

Para evaluar el rendimiento de un clasificador se utiliza la matriz de confusión, una tabla de doble entrada que compara las predicciones del modelo con los valores reales. Esta herramienta permite identificar cuántas decisiones fueron correctas y cuántas fueron errores, distinguiendo entre verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. Los verdaderos positivos corresponden a los casos en los que el modelo identifica correctamente la clase de interés. Los verdaderos negativos son aquellos en los que predice correctamente su ausencia. Los falsos positivos representan falsas alarmas, mientras que los falsos negativos implican omisiones, que en ciertos contextos pueden resultar especialmente graves.

		Clases Reales	
		Real Positivo	Real Negativo
Predicho	Positivo	Verdadero Positivo (VP)	Falso Positivo (FP)
	Negativo	Falso Negativo (FN)	Verdadero Negativo (VN)

Matriz de confusión. Fuente: Elaboración propia mediante IAG.



Para reforzar este concepto con una explicación visual y práctica, les recomendamos ver el siguiente video que aborda la matriz de confusión y las métricas de evaluación relacionadas.

También disponible desde:
<https://tinyurl.com/2dbdff9m>



› **Métricas de evaluación para clasificación**

Depender de una única métrica puede conducir a interpretaciones erróneas. Por eso, es fundamental comprender qué aspecto del rendimiento evalúa cada indicador y en qué contextos resulta más adecuado utilizarlo.

En primer lugar, la precisión general, conocida como accuracy, representa la proporción de predicciones correctas sobre el total de casos analizados. Aunque es la métrica más intuitiva, puede resultar engañosa cuando el conjunto de datos está desbalanceado. Por ejemplo, en un sistema de detección de fraude donde el 99 por ciento de las transacciones son legítimas, un modelo que siempre prediga “no es fraude” alcanzará un 99 por ciento de aciertos, pero no tendrá ninguna utilidad práctica.

En segundo término, la exactitud, denominada precision, permite evaluar cuán confiables son las predicciones positivas emitidas por el modelo. Más específicamente, indica qué proporción de los casos clasificados como positivos realmente lo son. En consecuencia, esta métrica adquiere especial relevancia cuando el costo de un falso positivo es elevado, como sucede en decisiones financieras, diagnósticos preliminares o sistemas de alerta.

Por otra parte, la recuperación o sensibilidad, conocida como recall o sensitivity, se centra en la capacidad del modelo para identificar todos los casos positivos reales. Es decir, mide qué proporción de los verdaderos positivos ha sido efectivamente detectada. Desde esta perspectiva, se vuelve prioritaria en contextos donde omitir un caso positivo puede generar consecuencias graves, como en el diagnóstico de enfermedades.

A su vez, la puntuación F1 integra exactitud y recuperación mediante su media armónica, ofreciendo un indicador equilibrado del desempeño. De este modo, evita que el modelo optimice una métrica en detrimento de la otra. Por ello, resulta especialmente útil cuando se necesita una medida sintética y las clases se encuentran desbalanceadas.

› **Metodología para la validación de resultados**

Para que un análisis sea científicamente sólido, es imprescindible respetar una regla fundamental: nunca evaluar un modelo con los mismos datos que se utilizaron para entrenarlo. Esta “regla de oro” permite evitar conclusiones optimistas que no se sostendrán cuando el modelo se enfrente a datos nuevos.

En este marco, la práctica habitual consiste en dividir el conjunto de datos original en distintas particiones con funciones claramente diferenciadas. En primer lugar, el conjunto de entrenamiento se destina a que el algoritmo identifique patrones y ajuste sus parámetros internos. En segundo término, el conjunto de validación permite comparar

alternativas, ajustar hiperparámetros y seleccionar la configuración más adecuada sin comprometer la evaluación final. Finalmente, el conjunto de prueba, también denominado test set, se reserva exclusivamente para realizar una evaluación definitiva y honesta de la capacidad de generalización del modelo elegido.

Ahora bien, cuando el volumen de datos disponible es reducido, esta división puede resultar ineficiente. En tales casos, se recurre a la validación cruzada, procedimiento mediante el cual el conjunto se divide en varias particiones y el modelo se entrena y evalúa en diferentes combinaciones. De esta manera, cada observación participa tanto en entrenamiento como en evaluación en distintas iteraciones, lo que permite obtener estimaciones más estables del rendimiento.

Más allá de las métricas y los procedimientos formales, ninguna evaluación es completa sin un análisis crítico. En efecto, el científico de datos debe verificar que las predicciones tengan coherencia lógica dentro del contexto del problema o del negocio en cuestión.

Además, es necesario considerar que en el mundo real los errores no tienen el mismo impacto. Un falso positivo y un falso negativo pueden implicar costos económicos o sociales muy diferentes. Por lo tanto, el analista debe decidir si conviene adoptar un modelo más conservador o más sensible, en función de las consecuencias asociadas a cada tipo de error.

Asimismo, resulta indispensable evitar prácticas como el p hacking, que consiste en manipular datos o probar múltiples hipótesis hasta encontrar resultados aparentemente significativos por azar. Finalmente, siempre se recomienda comparar el desempeño del modelo con una línea base simple, por ejemplo, predecir sistemáticamente la clase mayoritaria, para determinar si el aprendizaje automático está aportando un valor adicional real y no solo una mejora marginal.



Dando por finalizado el desarrollo del contenido, lo/a invitamos a trabajar con las actividades pertenecientes al módulo. Tenga presente que estaremos disponibles a través del espacio tutorial para que Ud. canalice sus dudas y comentarios.

MÓDULO 5 | GLOSARIO

Accuracy (Precisión general): Proporción de predicciones correctas sobre el total de casos evaluados. Puede resultar engañosa cuando las clases están desbalanceadas.

Aprendizaje supervisado: Enfoque de modelización en el que el algoritmo aprende a partir de datos etiquetados, es decir, ejemplos donde el resultado correcto es conocido.

Clasificación: Tipo de problema predictivo en el que la variable objetivo es categórica y el modelo debe asignar una instancia a una clase determinada.

Conjunto de entrenamiento: Subconjunto de datos utilizado para que el modelo aprenda patrones y relaciones.

Conjunto de prueba (test set): Subconjunto de datos reservado para evaluar el desempeño del modelo en información no utilizada durante el entrenamiento.

F1 Score: Métrica que combina precisión y recuperación mediante su media armónica, utilizada especialmente cuando las clases están desbalanceadas.

Falso Negativo (FN): Caso positivo real que el modelo clasifica incorrectamente como negativo.

Falso Positivo (FP): Caso negativo real que el modelo clasifica incorrectamente como positivo.

Generalización: Capacidad de un modelo para mantener un buen desempeño al aplicarse a datos nuevos no utilizados durante el entrenamiento.

Matriz de confusión: Tabla que resume los aciertos y errores de un modelo de clasificación mediante la comparación entre predicciones y valores reales.

Modelo: Representación simplificada de la realidad que permite describir patrones o realizar estimaciones sobre datos desconocidos.

Overfitting (sobreajuste): Situación en la que el modelo se ajusta excesivamente a los datos de entrenamiento, capturando ruido en lugar de patrones generales.

Precision (exactitud): Métrica que indica qué proporción de los casos predichos como positivos son realmente positivos.

Recall (sensibilidad o recuperación): Métrica que mide la proporción de casos positivos reales que el modelo logra identificar correctamente.

Regresión: Tipo de problema predictivo en el que la variable objetivo es numérica y continua.

Sesgo (bias): Error que surge cuando un modelo es demasiado simple para capturar la complejidad de los datos.

Subajuste (underfitting): Situación en la que el modelo es demasiado simple y no logra representar adecuadamente los patrones del conjunto de datos.

Validación cruzada (cross-validation): Técnica de evaluación que divide los datos en múltiples particiones para entrenar y probar el modelo en distintas combinaciones.

Varianza (variance): Medida de la sensibilidad del modelo a pequeñas variaciones en los datos de entrenamiento.

MÓDULO 5 | ACTIVIDADES



ACTIVIDAD N° 1:

Del análisis exploratorio al modelo

Luego de haber trabajado en el módulo anterior con análisis exploratorio (EDA), reflexione:

1. ¿Qué diferencia principal existe entre describir datos y modelar datos?
2. ¿Por qué la modelización implica necesariamente asumir una “simplificación” de la realidad?
3. Mencione un ejemplo cotidiano donde una predicción pueda resultar útil para la toma de decisiones.



ACTIVIDAD N° 2:

Interpretación conceptual de una matriz de confusión

Se analiza un modelo que detecta fraude en transacciones bancarias. De 1000 operaciones:

- › 50 eran fraudulentas.
- › El modelo detectó correctamente 40 fraudes.
- › Clasificó como fraude 70 operaciones en total.

Responda:

1. ¿Cuántos falsos positivos se produjeron?
2. ¿Cuántos falsos negativos hubo?
3. ¿Qué tipo de error considera más grave en este contexto? Justifique.



ACTIVIDAD N° 3:

Sobreajuste y generalización

Lea la siguiente situación:

Un modelo obtiene 99% de precisión en los datos de entrenamiento, pero solo 65% en datos nuevos.

1. ¿Qué fenómeno puede estar ocurriendo?
2. ¿Por qué este resultado es problemático?
3. ¿Qué importancia tiene separar datos de entrenamiento y prueba?

MÓDULO 6

Microobjetivos

- › Diferenciar el aprendizaje supervisado del no supervisado, para comprender el rol del clustering en el análisis de datos no etiquetados.
- › Describir el objetivo del agrupamiento en términos de similitud intraclase alta e interclase baja, con el fin de fundamentar conceptualmente la construcción de clústeres.
- › Caracterizar los principales algoritmos de clustering, tales como K-means, jerárquico, DBScan y espectral, para reconocer sus fundamentos generales y criterios básicos de aplicación.
- › Reconocer aplicaciones del agrupamiento en distintos dominios organizacionales y científicos, a fin de valorar su potencial para la generación de conocimiento relevante.
- › Interpretar el proceso de análisis y síntesis de clústeres, para vincular la segmentación obtenida con la toma de decisiones estratégicas en contextos organizacionales.
- › Identificar los límites técnicos del clustering, con el objetivo de comprender su sensibilidad a escalas, métricas y riesgos estadísticos en la construcción de resultados.
- › Analizar los principios de ética y reproducibilidad en el análisis de agrupamientos, para reconocer la importancia de considerar sesgos, privacidad, trazabilidad y documentación del proceso en la práctica profesional.

Contenidos

- **Etapas en Ciencia de Datos IV: Segmentación, agrupamiento y toma de decisiones**



Fuente: Freepik

El presente módulo constituye la etapa final y estratégica del ciclo de vida de un proyecto de ciencia de datos, momento en el cual el análisis técnico se transforma en estructuras organizadas y en decisiones accionables para la organización. En esta instancia, el foco se desplaza desde el modelado predictivo tradicional hacia el descubrimiento de patrones latentes en los datos y hacia la comunicación ética, clara y reproducible de los hallazgos a los distintos interesados.

- **Segmentación y agrupamiento: objetivo y aplicaciones iniciales**

La segmentación o agrupamiento, conocido como clustering, es una técnica de aprendizaje no supervisado que trabaja con datos que carecen de etiquetas o categorías pre-existentes. A diferencia del aprendizaje supervisado, donde un “maestro” proporciona la respuesta correcta para cada ejemplo, en el agrupamiento el algoritmo debe extraer sus propias conclusiones acerca de qué tienen en común los datos.

El desafío central del aprendizaje no supervisado consiste en identificar estructuras ocultas en información no etiquetada, sin contar con una señal externa de error o recompensa que indique qué tan buena es una solución. En este contexto, el modelo explora, organiza y propone posibles agrupaciones basándose exclusivamente en patrones internos.

El fin último del agrupamiento es particionar una población o conjunto de datos en sub-grupos o clústeres disjuntos basándose únicamente en su **similitud**. Este proceso busca maximizar dos condiciones estadísticas fundamentales. Por un lado, se pretende lograr una alta similitud intraclase, es decir, que los objetos dentro de un mismo grupo sean lo más parecidos posible entre sí. Por otro, se busca una baja similitud interclase, lo que implica que los objetos de distintos grupos sean claramente diferentes.

Es vital comprender que, en el agrupamiento no existe un resultado “correcto” único y definitivo. La validez de una segmentación es subjetiva y depende de la métrica elegida para evaluar los grupos y, sobre todo, de la utilidad práctica de la estructura descubierta tenga para el analista.

Ahora bien, dentro del campo de la segmentación es necesario distinguir entre enfoques supervisados y no supervisados, ya que esta diferencia incide directamente en la formulación del problema. La segmentación no supervisada responde a preguntas como “¿Nuestros clientes se organizan naturalmente en grupos diferenciados?”, sin perseguir un objetivo predictivo específico. En cambio, la segmentación supervisada se realiza con un propósito concreto, por ejemplo identificar grupos con alta probabilidad de abandonar un servicio (churn), utilizando una variable objetivo previamente definida.

Así, el agrupamiento genera grupos a partir de similitudes generales que pueden o no resultar útiles para un propósito particular, mientras que la segmentación supervisada asegura que los grupos se distingan respecto de una cualidad de interés explícita.

- **Algoritmos y heurísticas de agrupamiento**

Dentro del conjunto de técnicas de agrupamiento, K means es uno de los algoritmos más difundidos. Este método representa cada observación como un vector en un espacio de múltiples dimensiones y funciona mediante un procedimiento iterativo. En una primera etapa, particiona las entradas en k grupos. Luego, minimiza la suma de las distancias cuadradas entre cada punto y el centroide del grupo al que fue asignado. Finalmente, refina las asignaciones hasta alcanzar una situación de estabilidad estadística, es decir, hasta que los grupos dejan de modificarse de manera significativa. Una aplicación concreta consiste en identificar ubicaciones óptimas para reuniones de usuarios a partir de su distribución geográfica, utilizando los centros de los clústeres para informar la decisión.

Otro enfoque relevante es el agrupamiento jerárquico, particularmente en su variante aglomerativa (de abajo hacia arriba). En este caso, el procedimiento comienza considerando cada punto como un grupo independiente y, de manera progresiva, fusiona iterativamente los pares más cercanos. El resultado es una estructura en forma de árbol que permite visualizar distintos niveles de agrupamiento. Esta representación ofrece flexibilidad, ya que el analista puede elegir el nivel de detalle seleccionando el punto en el que se “corta” la jerarquía para definir los grupos finales.

Para determinar qué grupos deben fusionarse, existen distintos criterios de vinculación. El método Ward busca formar clústeres esféricos y cohesivos, generalmente de tamaño similar, minimizando la variación interna. El criterio complete, en cambio, utiliza las observaciones más alejadas para medir la distancia entre grupos, lo que tiende a generar conjuntos compactos y bien delimitados.

Además de estos enfoques tradicionales, existen métodos como DBScan y el agrupamiento espectral, que permiten detectar estructuras más complejas y clústeres que no necesariamente presentan formas esféricas. Estas alternativas amplían las posibilidades del análisis cuando los datos exhiben distribuciones irregulares o densidades variables.

El agrupamiento es extremadamente versátil y se utiliza como herramienta de exploración preliminar de dominio para identificar qué grupos naturales existen antes de emprender tareas de minería de datos más enfocadas. En marketing y ventas, por ejemplo, se emplea para identificar perfiles de clientes que representen segmentos significativos de la base de usuarios, lo que permite diseñar campañas diferenciadas en lugar de aplicar estrategias uniformes. En procesamiento de imágenes, K means se utiliza para la cuantización de colores, reduciendo la cantidad de tonalidades mediante el agrupamiento de píxeles similares para crear versiones estilizadas o comprimidas. También se emplea en redes sociales para el etiquetado automático de rostros mediante PCA. Asimismo, en finanzas y operaciones se emplea en scoring crediticio, detección de fraude y planificación de recursos humanos. En el ámbito de la ciencia y la medicina, se aplica en bioinformática para analizar secuencias génicas y estudiar comorbilidades. Finalmente, en sistemas de recomendación, empresas como Amazon o Netflix utilizan la similitud para sugerir productos o contenidos a usuarios con perfiles similares.

- ***Extracción de conocimiento: síntesis de hallazgos y soporte a la decisión***

La extracción de conocimiento es el proceso que consiste en transformar los patrones matemáticos descubiertos en información comprensible y útil para la toma de decisiones empresariales o científicas.

Dado que los datos no se etiquetan solos, es necesario un análisis humano para asignar etiquetas significativas a los grupos resultantes. En algunos casos, los nombres de los datos son informativos por sí mismos. Por ejemplo, en el agrupamiento de marcas de whisky, los nombres de los puntos de datos transmiten significado inmediato a los expertos y facilitan la interpretación de los clústeres obtenidos.

Otra estrategia efectiva es usar las asignaciones de clústeres como etiquetas de clase y entrenar un algoritmo de aprendizaje supervisado (como un árbol de decisión) para ge-

nerar un clasificador por grupo. Al inspeccionar estas reglas, se obtiene una descripción clara de qué diferencia a un clúster de los demás.

De manera complementaria, cada centro de clúster puede emplearse para definir una “persona” de cliente. En este caso, la descripción se construye a partir de los valores de los atributos asociados al centroide correspondiente, lo que permite sintetizar las características típicas de cada segmento.

Desde una perspectiva estratégica, el agrupamiento funciona como un insumo clave para procesos de decisión que buscan responder preguntas tales como: ¿Qué productos deberían ofrecerse o desarrollarse? ¿Cómo deberían estructurarse los equipos de atención al cliente o ventas? En este sentido, los clústeres no constituyen un fin en sí mismos, sino una base para orientar acciones concretas. Un ejemplo histórico notable es el de GE Capital, donde se agruparon clientes según su uso de tarjetas y comportamiento de pago. Aunque el agrupamiento reveló cinco comportamientos de crédito distintos, los datos necesarios no estaban disponibles al momento de otorgar créditos nuevos. Por ello, los científicos de datos volvieron al inicio del ciclo para construir un modelo predictivo que estimara la probabilidad de que un cliente nuevo cayera en uno de esos grupos basándose en la información disponible al momento de la solicitud.

- ***Identificación de temas, comunicación de resultados y responsabilidad en ciencia de datos***

El modelado de temas, a través de técnicas como la Asignación de Dirichlet Latente, permite identificar estructuras temáticas subyacentes en grandes volúmenes de texto. Este enfoque descubre asociaciones recurrentes entre palabras y facilita la detección de categorías latentes sin necesidad de etiquetas previas. De este modo, es posible comprender intereses, tendencias o ejes discursivos presentes en colecciones extensas de documentos.

En una línea similar, el análisis de coocurrencia, también conocido como análisis de canasta de mercado, busca identificar asociaciones frecuentes entre productos o eventos a partir de registros transaccionales. Por ejemplo, puede revelar que ciertos artículos se compran juntos con una frecuencia mayor a la esperada. Estos patrones no solo describen comportamientos, sino que pueden orientar decisiones comerciales concretas, como promociones combinadas o estrategias de exhibición.

Para estructurar este tipo de decisiones, el uso de marcos como el de valor esperado permite descomponer problemas de negocio complejos en tareas de ciencia de datos comprensibles y abordables. En lugar de formular preguntas generales y abstractas, este enfoque traduce los objetivos estratégicos en estimaciones cuantificables que pueden modelarse. Los modelos de predicción salarial, por ejemplo, ilustran cómo el análisis de patrones históricos permite realizar predicciones informadas que sirven de apoyo a decisiones organizacionales más fundamentadas.

Ahora bien, descubrir patrones y traducirlos en modelos no es suficiente. El éxito de un científico de datos depende de su capacidad para comunicar la “historia” en los datos, revelando no solo el conocimiento extraído, sino también cómo los modelos impactarán el funcionamiento de la organización.

La visualización de datos es una herramienta fundamental que permite tanto la exploración como la comunicación clara de información compleja. Una imagen puede valer más que mil palabras, pero solo si dice las palabras correctas y transmite el mensaje adecuado sin que se pierda su sentido. En este marco, la visualización cumple un doble propósito: por un lado, explorar los datos para comprender su estructura interna, identificar patrones, tendencias o valores atípicos; por otro, comunicar hallazgos de manera efectiva para informar a otros y facilitar la toma de decisiones. Producir visualizaciones de alta calidad requiere habilidad técnica y criterio analítico, ya que una representación bien construida puede revelar aspectos que no son evidentes en los datos en bruto, mientras que un diseño inadecuado puede inducir interpretaciones erróneas.

En cuanto a las herramientas disponibles, Python ofrece bibliotecas como Matplotlib para gráficos básicos, Seaborn para mejoras estéticas y visualizaciones estadísticas más complejas, D3.js para desarrollos interactivos en la web y Bokeh para gráficos modernos e interactivos. Ahora bien, al momento de comunicar resultados, es importante distinguir entre presentaciones y reportes escritos. Las diapositivas constituyen el medio más común y de mayor impacto, pero no deben tratarse como informes extensos: deben ser breves, claras y convincentes, priorizando el contenido gráfico sobre el textual. Comprender a la audiencia resulta decisivo; si se requieren detalles técnicos, pueden ofrecerse, pero si el interés decae, conviene escalar hacia una visión más general y estratégica.

Al mismo tiempo, el analista debe ser consciente de las limitaciones inherentes a sus herramientas y a los propios datos con los que trabaja. En primer lugar, los datos del mundo real suelen ser desordenados y caóticos; rara vez llegan en condiciones ideales para el análisis. Por ello, la limpieza, transformación y manipulación constante de la información constituye una de las habilidades más importantes del científico de datos. En segundo lugar, muchas técnicas de agrupamiento son sensibles a la escala de los datos. Esto implica que variables con magnitudes mayores pueden dominar el análisis si no se realizan previamente reescalados o estandarizaciones adecuadas, lo que podría introducir sesgos no deseados en los resultados.

En esta misma línea de cautela metodológica, la evaluación de los modelos también requiere atención. La precisión, considerada de manera aislada, puede resultar engañosa. Por esta razón, es necesario definir métricas que permitan distinguir adecuadamente un buen modelo de uno inadecuado según el problema de negocio específico. Herramientas como la matriz de confusión permiten analizar verdaderos positivos, falsos positivos y otros tipos de error de manera más completa y contextualizada. Del mismo modo, deben evitarse las trampas estadísticas: las hipótesis deben predefinirse antes del análisis para impedir la extracción selectiva de datos o el *p* hacking, es decir, la manipulación de la información hasta encontrar resultados estadísticamente significativos por azar. Además, las estadísticas pueden ser particularmente sensibles a valores atípicos o a sesgos introducidos durante la recopilación de los datos.

Estas precauciones metodológicas nos llevan a una dimensión más compleja del tema, las consideraciones éticas y la responsabilidad social. La ciencia de datos no ocurre en un vacío; tiene profundas implicaciones sociales y éticas. En primer lugar, existe el riesgo de construir modelos que capturen y perpetúen el ruido o los sesgos presentes en los datos de entrenamiento. Si estos sesgos no se identifican y analizan con criterios rigurosos,

pueden reproducirse en decisiones automatizadas con impacto real sobre personas y organizaciones.

En segundo lugar, el manejo de la Información de Identificación Personal debe realizarse bajo estrictas normativas legales y criterios claros de protección. Esto implica definir con precisión quién accede a los datos, con qué finalidad se recopilan, cuánto tiempo se almacenan y en qué condiciones pueden compartirse. También supone aplicar prácticas concretas como la anonimización o seudonimización cuando sea posible, la minimización de datos para recolectar únicamente lo necesario y la implementación de protocolos de seguridad que reduzcan riesgos de filtraciones. En ámbitos como la salud, las finanzas o la educación, una gestión inadecuada de datos sensibles puede afectar derechos fundamentales y generar consecuencias legales y sociales significativas.

Ahora bien, la responsabilidad social no se limita a evitar daños. La ciencia de datos también puede orientarse hacia el bien social. Los profesionales pueden utilizar sus competencias para optimizar la asignación de recursos públicos, mejorar políticas de salud, fortalecer sistemas educativos o diseñar intervenciones más eficaces en contextos de vulnerabilidad. En estos casos, el impacto del análisis se mide no solo en términos de eficiencia, sino también en términos de equidad y mejora de condiciones de vida. La dimensión ética, por lo tanto, no es un agregado externo al trabajo técnico, sino un criterio que debe guiar la formulación del problema y la interpretación de los resultados.

La transparencia constituye otro pilar fundamental. Documentar las limitaciones conocidas, los supuestos adoptados y los posibles sesgos de los conjuntos de datos y de los modelos utilizados permite que otros comprendan el alcance real de las conclusiones. Esta práctica no solo fortalece la credibilidad del análisis, sino que habilita la revisión crítica y la mejora continua.

En estrecha relación con ello se encuentra la reproducibilidad, entendida como estándar científico básico. Un proyecto de ciencia de datos que no puede reproducirse carece de solidez metodológica. La reproducibilidad garantiza que cada número, gráfico o conclusión pueda ser validado por terceros bajo las mismas condiciones. Para lograrlo, es indispensable asegurar la trazabilidad y el linaje de los datos: debe registrarse quién produjo cada dato, cómo fue transformado y con qué propósito. Esta documentación permite la revisión por pares, facilita auditorías internas o externas y contribuye al cumplimiento de exigencias legales.

En este marco, el dominio de herramientas que integran código, texto y visualizaciones en un mismo entorno autodocumentado resulta especialmente valioso. Plataformas como IPython o Jupyter Notebooks permiten mantener un registro exacto de los pasos seguidos, favorecen la colaboración entre equipos y reducen la probabilidad de errores derivados de procesos no documentados.

Finalmente, el cierre del proyecto no coincide necesariamente con la obtención de resultados analíticos. En muchos casos, implica producir código que será ejecutado regularmente por otros, ya sea para procesos de analítica por lotes o para el entrenamiento continuo de modelos futuros. Esto exige estándares de calidad, claridad y mantenimiento que trascienden el análisis exploratorio inicial.



Énfasis

En este sentido, la ciencia de datos es tanto un arte como una ciencia, donde la capacidad de encontrar orden en el caos de los datos debe equilibrarse con una comunicación honesta, una ética inquebrantable y un rigor técnico que garantice la posibilidad de replicar, auditar y sostener en el tiempo el conocimiento generado.



Actividad

Dando por finalizado el desarrollo del contenido, lo/a invitamos a trabajar con las actividades pertenecientes al módulo. Tenga presente que estaremos disponibles a través del espacio tutorial para que Ud. canalice sus dudas y comentarios.



Evaluación

Luego de haber estudiado la materia y de haber resuelto las actividades, Ud. está en condiciones de resolver la segunda parte de la evaluación integradora.

› **Palabras finales**

Al concluir este recorrido por Introducción a la Ciencia de Datos, usted ha adquirido una visión integrada del campo: desde el reconocimiento de los tipos y fuentes de datos, hasta la aplicación de consultas simples en SQL, procesos básicos de ETL, análisis exploratorio y primeras aproximaciones a la modelización y segmentación. Estos aprendizajes le han permitido ejercitar competencias clave como la comunicación responsable, el trabajo ético con datos y la capacidad de interpretar hallazgos iniciales con rigor y claridad.

Cursar esta asignatura le ha brindado las bases necesarias para comprender el ciclo de vida de un proyecto de ciencia de datos y desarrollar habilidades transversales de análisis, colaboración y pensamiento crítico. Con este fundamento, usted está preparado/a para profundizar sus conocimientos en las materias siguientes y continuar construyendo su perfil profesional en el campo de la ciencia de datos.

MÓDULO 6 | GLOSARIO

Agrupamiento jerárquico: Método que fusiona iterativamente puntos o grupos cercanos formando una estructura jerárquica que permite distintos niveles de resolución.

Aprendizaje no supervisado: Enfoque de aprendizaje automático que trabaja con datos sin etiquetas y busca descubrir estructuras o patrones ocultos.

Centroide: Vector promedio que representa el centro estadístico de un clúster y sintetiza sus características principales.

Clustering (agrupamiento): Técnica que divide un conjunto de datos en clústeres según su similitud, sin una variable objetivo predefinida.

K-means: Algoritmo de clustering que particiona los datos en k grupos minimizando la distancia cuadrática entre cada punto y el centroide de su clúster.

Modelado de temas (LDA): Técnica que identifica temas latentes en grandes colecciones de documentos a partir de patrones de co-ocurrencia de palabras.

Reproducibilidad: Principio científico que exige que los resultados de un análisis puedan replicarse siguiendo el mismo proceso, garantizando trazabilidad y validación.

Segmentación supervisada: Proceso de agrupamiento orientado a una variable objetivo específica, donde los grupos se diferencian respecto a una cualidad de interés.

Sensibilidad a la escala: Propiedad de ciertos algoritmos que los hace depender de la magnitud de las variables, requiriendo normalización o estandarización previa.

Sesgo en los modelos: Distorsión sistemática derivada de los datos de entrenamiento que puede generar resultados injustos o incorrectos.

Similitud intraclase: Nivel de semejanza entre los elementos que pertenecen a un mismo clúster; en una buena segmentación debe ser alta.

Similitud interclase: Nivel de diferencia entre elementos de distintos clústeres; en una buena segmentación debe existir una clara separación entre grupos.

MÓDULO 6 | ACTIVIDADES



Actividad

ACTIVIDAD N° 1:

Supervisado vs. no supervisado

Una empresa de telecomunicaciones quiere:

- › Identificar grupos naturales de clientes según su comportamiento de consumo.
- › Detectar clientes con alta probabilidad de cancelar el servicio.

A partir de ello:

1. Indicar qué enfoque corresponde a cada caso (supervisado o no supervisado) y justificar la elección.
2. Explicar qué información adicional sería necesaria en cada situación.



Actividad

ACTIVIDAD N° 2:

Interpretación de clústeres

Se informa que un algoritmo K-means identificó 3 clústeres de clientes con las siguientes características promedio:

- › Grupo A: jóvenes, alto uso de redes sociales, bajo gasto mensual.
- › Grupo B: adultos, gasto medio, consumo estable.
- › Grupo C: mayores ingresos, alto gasto, baja frecuencia de uso.

A partir de la situación dada, responda:

1. Proponer un nombre descriptivo para cada grupo.
2. Describir qué estrategia comercial podría aplicarse a cada segmento.
3. Explicar por qué el clustering no tiene una “única respuesta correcta”.



Actividad

ACTIVIDAD N° 3:

Ética y reproducibilidad

Una organización utiliza segmentación para asignar límites de crédito. Se detecta que ciertos grupos socioeconómicos reciben sistemáticamente peores condiciones.

1. Identificar posibles fuentes de sesgo.
2. Explicar por qué la reproducibilidad es importante en este contexto.
3. Proponer dos medidas para mejorar la transparencia del modelo.
4. Reflexionar sobre el rol social del científico de datos en este caso.